



本章主题

- 确定性推理
 - 消解演绎推理
 - 规则演绎系统
- 不确定性推理
 - 概率推理
 - 主观贝叶斯方法

2022/11/2

不确定性推理

□ 推理：从已知事实（证据）出发，通过运用相关知识逐步推出结论或者证明某个假设成立或不成立的思维过程。

□ 不确定性推理：从不确定性的初始证据出发，通过运用不确定性的知识，最终推出具有一定程度的不确定性但却是合理或者近乎合理的结论的思维过程。

2022/11/2

不确定性推理中的基本问题

□ 不确定性推理中所用的知识和证据都具有某种程度的不确定性，这就给推理机的设计与实现增加了复杂性和难度。

□ 在不确定性推理中，除了需要解决在确定性推理中所提到的推理方向、推理方法、控制策略等基本问题外，一般还需要解决不确定性的表示与度量、不确定性的匹配、不确定性的传递算法和不确定性的合成等重要问题。

2022/11/2

不确定性的表示与度量

□ 知识的不确定性表示：

- 考虑因素：(1) 要能根据领域问题特征把不确定性比较准确地描述出来以满足问题求解的需要；(2) 要便于推理过程中推算不确定性。
- 专家系统中通常用一个数值表示相应知识的不确定性程度，称为知识的静态强度。
- 表示：概率， $[0, 1]$ ，0接近于假；1接近于真
可信度， $[-1, 1]$ ，大于0接近于真，小于0接近于假。

2022/11/2

不确定性的表示与度量

□ 证据的不确定性表示：

- 证据的分类：按照证据的组织形式，可分为基本证据和组合证据；按照证据的不同来源，可分为初始证据和中间结论。
- 证据的不确定性也通常用一个数值代表相应证据的不确定性程度，称为动态强度。
- 表示：基本证据，常与知识的表示方法一致，如概率、可信度等；组合证据，组合证据的不确定性算法。

2022/11/2

不确定性的表示与度量

□ **组合证据的不确定性算法**: 证据合取和证据析取的不确定性算法统称为组合证据的不确定性算法。

➢ **最大最小法**:

$$C(E_1 \text{ AND } E_2) = \min\{C(E_1), C(E_2)\}; C(E_1 \text{ OR } E_2) = \max\{C(E_1), C(E_2)\}$$

➢ **概率方法**:

$$C(E_1 \text{ AND } E_2) = C(E_1)C(E_2); C(E_1 \text{ OR } E_2) = C(E_1) + C(E_2) - C(E_1)C(E_2)$$

➢ **有界方法**:

$$C(E_1 \text{ AND } E_2) = \max\{0, C(E_1) + C(E_2) - 1\}; C(E_1 \text{ OR } E_2) = \min\{1, C(E_1) + C(E_2)\}$$



7

2022/11/2

不确定性的表示与度量

□ **考虑不确定性的度量方法与度量范围时必须注意**:

- 量度应能充分表达相应知识和证据不确定性的程度;
- 量度范围的指定应便于领域专家和用户对不确定性的估计;
- 量度应便于对不确定性的传递进行计算;
- 量度的确定应是直观的并有相应的理论依据。

□ 例如, 在MYCIN等专家系统中, 用可信度来表示知识和证据的不确定性, 其取值范围为[-1, 1]。



8

2022/11/2

不确定性的匹配算法

□ **不确定性的匹配算法**: 不确定的前提条件与不确定的证据匹配。

□ 知识和证据都具有不确定性, 而且知识所要求的不确定性程度与证据实际具有的不确定性程度不一定相同。

□ **解决方法**: 设计一个计算相似程度的算法, 给出相似的限度(阈值)。

□ 如果落在指定的限度内, 就称它们是可匹配的, 相应的知识可被应用; 否则称它们是不可匹配的, 相应的知识不可应用。



9

2022/11/2

不确定性的更新(传递)算法

□ 在不确定性推理中, 由于证据和知识均是不确定的, 那么就存在以下两个问题:

- ① 在每一步推理中, 如何把证据及知识的不确定性传递给结论。
- ② 在多步推理中, 如何把初始证据的不确定性传递给最终结论。

□ **已知规则前提即证据E的不确定性C(E)和规则的强度f(H,E), 其中H表示假设, 求H的不确定性C(H)。即定义算法g₁, 使得:**

$$C(H) = g_1[C(E), f(H, E)]$$



10

2022/11/2

不确定性结论的合成

□ 在不确定性推理过程中, 很可能会出现由**多个不同知识推出同一结论**, 并且推出的结论的**不确定性程度又各不相同**。对此, 需要采用某种算法对这些不同的不确定性进行合成, 求出该结论的综合不确定性。

□ 根据独立的证据E₁和E₂, 分别求得假设H的不确定性为C₁(H)和C₂(H)。求出证据E₁和E₂的组合导致结论H的不确定性C(H), 即定义算法g₂, 使得:

$$C(H) = g_2[C_1(E), C_2(E)]$$



11

2022/11/2

可信度方法

□ 1975年肖特里菲(E. H. Shortliffe)等人在确定性理论(theory of confirmation)的基础上, 结合概率论等理论提出的一种不确定性推理方法。

□ 它对许多实际应用都是一个合理而有效的推理模式, 因此在专家系统等领域获得较广泛的应用。

□ 优点: 直观、简单, 且效果好。



12

2022/11/2

可信度方法

- **可信度**是指人们根据以往经验对某个事物或现象为真的程度的一个判断，或者说是人们对某个事物或现象为真的相信程度。
- 例如，张三昨天没来上课，理由是头疼。就此理由，只有以下两种可能：一是真的头疼了，理由为真；二是没有头疼，理由为假。但就听话人而言，因不能确切知道，**就只能某种程度上相信**，即可信度。



13

2022/11/2

可信度方法

- 可信度具有一定地主观性，较难把握。但对某一特定领域，让该领域专家给出可信度还是可行的。
- **C-F模型**：基于可信度表示的不确定性推理的基本方法。



14

2022/11/2

可信度方法

□ 知识的不确定性表示

➢ 产生式规则表示：

IF E THEN H ($CF(H,E)$)

其中，E是知识的前提条件；H是知识的结论； $CF(H,E)$ 为可信度因子（certainty factor），反映前提条件与结论的联系强度。

IF 头疼 AND 流涕 THEN 感冒 (0.8)



15

2022/11/2

可信度方法

□ 知识的不确定性表示

➢ $CF(H,E)$ 的取值范围：[-1,1]。

➢ 若由于相应证据的出现增加结论H为真的可信度，则 $CF(H,E) > 0$ ，证据的出现越是支持H为真，就使 $CF(H,E)$ 的值越大。

➢ 反之， $CF(H,E) < 0$ ，证据的出现越是支持H为假， $CF(H,E)$ 的值就越小。

➢ 若证据的出现与否与H无关，则 $CF(H,E) = 0$ 。



16

2022/11/2

可信度方法

□ 证据的不确定性表示

$CF(E) = 0.7$: E的可信度为0.7

➢ 证据E的可信度取值范围：[-1, 1]。

➢ 对于初始证据，若所有观察S能肯定它为真，则 $CF(E) = 1$ ；若肯定它为假，则 $CF(E) = -1$ 。

➢ 若以某种程度为真，则 $0 < CF(E) < 1$ 。若以某种程度为假，则 $-1 < CF(E) < 0$ 。

➢ 若未获得任何相关的观察，则 $CF(E) = 0$ 。



17

2022/11/2

可信度方法

□ 组合证据的不确定性算法

➢ 组合证据为多个单一证据的合取。

$E = E_1 \text{ AND } E_2 \text{ AND } \dots \text{ AND } E_n$

$CF(E) = \min\{CF(E_1), CF(E_2), \dots, CF(E_n)\}$

➢ 组合证据为多个单一证据的析取。

$E = E_1 \text{ OR } E_2 \text{ OR } \dots \text{ OR } E_n$

$CF(E) = \max\{CF(E_1), CF(E_2), \dots, CF(E_n)\}$



18

2022/11/2

可信度方法

□ 不确定性的表示

➢ 静态强度 $CF(H, E)$: 知识的强度, 即当E所对应的证据为真时对H的影响程度。

➢ 动态强度 $CF(E)$: 证据E当前的不确定性程度。



19

2022/11/2

可信度方法

□ 不确定性的传递算法

➢ C-I模型中的不确定性推理: 从不确定性的初始证据出发, 通过运用相关的不确定性知识, 最终推出结论并求出结论的可信度值。结论H的可信度由下式计算

$$CF(H) = CF(H, E) \times \max\{0, CF(E)\}$$

➢ 当 $CF(E) < 0$ 时, 则 $CF(H) = 0$, 即该模型没考虑E为假对H的影响。

➢ 当 $CF(E) = 1$ 时, 则 $CF(H) = CF(H, E)$, 则规则强度 $CF(H, E)$ 实际上是在E为真时H的可信度。



20

2022/11/2

可信度方法

□ 不确定性结论的合成算法

➢ 设知识:

IF E_1 THEN H ($CF(H, E_1)$)

IF E_2 THEN H ($CF(H, E_2)$)

(1) 分别对每一条知识求出 $CF(H)$:

$$CF_1(H) = CF(H, E_1) \times \max\{0, CF(E_1)\}$$

$$CF_2(H) = CF(H, E_2) \times \max\{0, CF(E_2)\}$$



21

2022/11/2

可信度方法

□ 不确定性结论的合成算法

(2) 求出 E_1 与 E_2 对H的综合影响所形成的可信度:

$$CF(H) = \begin{cases} CF_1(H) + CF_2(H) - CF_1(H)CF_2(H) & CF_1(H) \geq 0, CF_2(H) \geq 0 \\ CF_1(H) + CF_2(H) + CF_1(H)CF_2(H) & CF_1(H) < 0, CF_2(H) < 0 \\ \frac{CF_1(H) + CF_2(H)}{1 - \min\{|CF_1(H)|, |CF_2(H)|\}} & CF_1(H) \text{ 与 } CF_2(H) \text{ 异号} \end{cases}$$



22

2022/11/2

可信度方法

□ 例题:

设有如下知识:

R1: IF E_1 THEN H (0.8)

R2: IF E_2 THEN H (0.6)

R3: IF E_3 THEN H (-0.5)

R4: IF E_4 AND (E_5 OR E_6) THEN E_1 (0.7)

R5: IF E_7 AND E_8 THEN E_3 (0.9)

已知: $CF(E_2) = 0.8$, $CF(E_4) = 0.5$, $CF(E_5) = 0.6$, $CF(E_6) = 0.7$, $CF(E_7) = 0.6$, $CF(E_8) = 0.9$ 。

求: $CF(H)$



23

2022/11/2

可信度方法

解:

(1) 对每一条规则求出 $CF(H)$:

$$\begin{aligned} \text{R4: } CF(E_1) &= 0.7 \times \max\{0, CF(E_4 \text{ AND } (E_5 \text{ OR } E_6))\} \\ &= 0.7 \times \max\{0, \min\{CF(E_4), CF(E_5 \text{ OR } E_6)\}\} \\ &= 0.7 \times \max\{0, \min\{CF(E_4), \max\{CF(E_5), CF(E_6)\}\}\} \\ &= 0.7 \times \max\{0, \min\{0.5, \max\{0.6, 0.7\}\}\} \\ &= 0.7 \times 0.5 \\ &= 0.35 \end{aligned}$$



24

2022/11/2

可信度方法

(1) 对每一条规则求出 $CF(H)$:

$$\begin{aligned} R5: \quad CF(E_3) &= 0.9 \times \max\{0, CF(E_7 \text{ AND } E_8)\} \\ &= 0.9 \times \max\{0, \min\{CF(E_7), CF(E_8)\}\} \\ &= 0.9 \times \max\{0, \min\{0.6, 0.9\}\} \\ &= 0.9 \times 0.6 \\ &= 0.54 \end{aligned}$$



25

2022/11/2

可信度方法

(1) 对每一条规则求出 $CF(H)$:

$$\begin{aligned} R1: \quad CF_1(H) &= 0.8 \times \max\{0, CF(E_1)\} & R2: \quad CF_2(H) &= 0.6 \times \max\{0, CF(E_2)\} \\ &= 0.8 \times \max\{0, 0.35\} & &= 0.6 \times \max\{0, 0.8\} \\ &= 0.28 & &= 0.48 \\ R3: \quad CF_3(H) &= -0.5 \times \max\{0, CF(E_3)\} \\ &= -0.5 \times \max\{0, 0.54\} \\ &= -0.27 \end{aligned}$$



26

2022/11/2

可信度方法

(2) 根据结论不确定性的合成算法得到:

$$\begin{aligned} CF_{1,2}(H) &= CF_1(H) + CF_2(H) - CF_1(H)CF_2(H) \\ &= 0.28 + 0.48 - 0.28 \times 0.48 = 0.63 \end{aligned}$$

$$\begin{aligned} CF_{1,2,3}(H) &= \frac{CF_{1,2}(H) + CF_3(H)}{1 - \min\{|CF_{1,2}(H)|, |CF_3(H)|\}} \\ &= \frac{0.63 - 0.27}{1 - \min\{0.63, 0.27\}} \\ &= \frac{0.36}{0.73} = 0.49 \end{aligned}$$



27

2022/11/2

本章主题

- 确定性推理
 - 消解演绎推理
 - 规则演绎系统
- 不确定性推理
 - 概率推理
 - 主观贝叶斯方法



28

2022/11/2

概率推理方法 (贝叶斯推理)

□ 假设有产生式规则: if E then H , 证据(或前提条件) E 不确定性的概率为 $P(E)$, 概率方法不精确推理的目的就是求出在证据 E 下结论 H 发生的概率 $P(H|E)$ 。

□ 使用贝叶斯方法用于不精确推理的一个原始条件是: 前提 E 的概率 $P(E)$ 、 H 成立时 E 出现的条件概率 $P(E|H)$ 、 H 的先验概率 $P(H)$ 已知。如果只使用这一条规则进行一步推理, 则可使用如下最简形式的贝叶斯公式计算得到 H 的后验概率:

$$P(H|E) = \frac{P(H)P(E|H)}{P(E)}$$



29

2022/11/2

概率推理方法

□ 若一个证据 E 支持多个假设 $H_1, H_2, \dots, H_n$, 即 IF E THEN H_i , $i = 1, 2, \dots, n$, 则可得贝叶斯公式:

$$P(H_i|E) = \frac{P(H_i)P(E|H_i)}{\sum_{j=1}^n P(H_j)P(E|H_j)}, \quad i = 1, 2, \dots, n$$



30

2022/11/2

概率推理方法

□ 例：设 H_1, H_2 是两个结论， E 是支持这些结论的证据，且已知：

$$P(H_1)=0.4, P(H_2)=0.5, P(E|H_1)=0.6, P(E|H_2)=0.3。$$

求： $P(H_1|E), P(H_2|E)$ 。

解：根据贝叶斯公式有

$$P(H_1|E) = \frac{P(H_1) \cdot P(E|H_1)}{P(H_1) \cdot P(E|H_1) + P(H_2) \cdot P(E|H_2)}$$

$$= \frac{0.24}{0.24+0.15} = 0.62$$

同理可求得 $P(H_2|E) = 0.38$

计算结果表明：由于证据 E 的出现， H_1 成立的可能性增加了，而 H_2 成立的可能性却下降了。



31

2022/11/2

概率推理方法

□ 若有多个证据 $E_1, E_2, \dots, E_m$ 支持多个假设 $H_1, H_2, \dots, H_n$ (m 为证据 E 的个数， n 为结论 H 的个数)，并且每个证据都以一定程度支持结论，则可得贝叶斯公式：

$$P(H_i|E_1 E_2 \dots E_m) = \frac{P(E_1|H_i)P(E_2|H_i)\dots P(E_m|H_i)P(H_i)}{\sum_{j=1}^n P(E_1|H_j)P(E_2|H_j)\dots P(E_m|H_j)P(H_j)}, \quad i=1,2,\dots,n$$

□ 此时，只要已知 H_i 的先验概率 $P(H_i)$ 及 H_i 成立时证据 $E_1, E_2, \dots, E_m$ 出现的条件概率 $P(E_1|H_i), P(E_2|H_i), \dots, P(E_m|H_i)$ ，就可以利用上述公式计算出在 $E_1, E_2, \dots, E_m$ 出现情况下的条件概率 $P(H_i|E_1 E_2 \dots E_m)$



32

2022/11/2

概率推理方法

□ 例：已知：

$$P(H_1)=0.4, P(H_2)=0.3, P(H_3)=0.3$$

$$P(E_1|H_1)=0.5, P(E_1|H_2)=0.6, P(E_1|H_3)=0.3$$

$$P(E_2|H_1)=0.7, P(E_2|H_2)=0.9, P(E_2|H_3)=0.1$$

求： $P(H_1|E_1 E_2), P(H_2|E_1 E_2), P(H_3|E_1 E_2)$ 。

解：根据题意有 $m=2, n=3$ ，分别将 $i=1,2,3$ 代入下列贝叶斯公式：

$$P(H_i|E_1 E_2 \dots E_m) = \frac{P(E_1|H_i)P(E_2|H_i)\dots P(E_m|H_i)P(H_i)}{\sum_{j=1}^n P(E_1|H_j)P(E_2|H_j)\dots P(E_m|H_j)P(H_j)}, \quad i=1,2,\dots,n$$



33

2022/11/2

概率推理方法

$$P(H_1|E_1 E_2) = \frac{P(E_1|H_1)P(E_2|H_1)P(H_1)}{P(E_1|H_1)P(E_2|H_1)P(H_1) + P(E_1|H_2)P(E_2|H_2)P(H_2) + P(E_1|H_3)P(E_2|H_3)P(H_3)}$$

$$= 0.45$$

同理可得：

$$P(H_2|E_1 E_2) = 0.52$$

$$P(H_3|E_1 E_2) = 0.03$$

□ 计算结果表明：由于证据 E_1, E_2 的出现，使 H_1 和 H_2 成立的概率有不同程度的提高，而 H_3 成立的概率下降了。



34

2022/11/2

概率推理方法

□ 概率推理方法具有较强的理论基础和较好的数学描述。

□ 当证据和结论彼此独立时，计算并不复杂。但是，应用这种方法时要求给出结论 H_i 的先验概率 $P(H_i)$ 及证据 E_j 的条件概率 $P(E_j|H_i)$ ，要获取这些概率数据是相当困难的。

□ 贝叶斯公式的应用条件相当严格，即要求各事件彼此独立。如果证据间存在依赖关系，那么不能直接采用这种方法。



35

2022/11/2

本章主题

● 确定性推理

消解演绎推理

规则演绎系统

● 不确定性推理

概率推理

主观贝叶斯方法



36

2022/11/2

主观贝叶斯方法

- 在贝叶斯推理中，先验概率 $P(H_i)$ 及证据 E 的条件概率 $P(E|H_i)$ 是很难给出的。
- 杜达 (Duda) 和哈特 (Hart) 等人在贝叶斯公式的基础上，于1976年提出了**主观贝叶斯方法 (又称为主观概率论)**，建立了不精确推理模型，并把它成功地应用于PROSPECTOR专家系统。



37

2022/11/2

知识不确定性的表示

- 主观贝叶斯方法采用产生式规则表示知识：

$$\text{if } E \text{ then } (LS, LN) H$$

其中 (LS, LN) 表示该知识的静态强度，称LS为上式成立的充分性因子，LN为上式成立的必要性因子，分别衡量证据 E 对结论 H 的支持程度和 $\sim E$ 对 H 的支持程度。



38

2022/11/2

知识不确定性的表示

- LS与LN的定义：

$$LS = \frac{P(E|H)}{P(E|\sim H)}, \quad LN = \frac{P(\sim E|H)}{P(\sim E|\sim H)} = \frac{1-P(E|H)}{1-P(E|\sim H)}$$

LS 和 LN 的取值范围是 $[0, +\infty)$ ，其具体数值由领域专家决定。



39

2022/11/2

知识不确定性的表示

- 主观贝叶斯方法的推理过程即为根据前提 E 的概率 $P(E)$ ，利用规则的 LS 和 LN，把结论 H 的先验概率 $P(H)$ 更新为后验概率 $P(H|E)$ 的过程。

- 定义几率函数 $O(X)$ ：

$$O(X) = \frac{P(X)}{P(\sim X)}$$

即事件 X 发生的几率等于 X 的概率与 $\sim X$ 的概率之比。由式可知，随着 $P(X)$ 的增大， $O(X)$ 也随之增大，并且可把取值为 $[0, 1]$ 的 $P(X)$ 放大为取值为 $[0, +\infty)$ 的 $O(X)$ 。



40

2022/11/2

知识不确定性的表示

- 根据贝叶斯公式：

$$P(H|E) = \frac{P(H)P(E|H)}{P(E)} \quad P(\sim H|E) = \frac{P(\sim H)P(E|\sim H)}{P(E)}$$

两式相除，可得：

$$\frac{P(H|E)}{P(\sim H|E)} = \frac{P(E|H)}{P(E|\sim H)} \cdot \frac{P(H)}{P(\sim H)}$$



41

2022/11/2

知识不确定性的表示

- 根据概率函数公式可得 (修改的贝叶斯公式)：

$$O(H|E) = LS \cdot O(H)$$

$$O(H|\sim E) = LN \cdot O(H)$$

- 以上两式表明：

- 当 E 为真时，可利用 LS 将 H 的先验几率 $O(H)$ 更新为其后验几率 $O(H|E)$ ；
- 当 E 为假时，可利用 LN 将 H 的先验几率 $O(H)$ 更新为其后验几率 $O(H|\sim E)$ 。



42

2022/11/2

知识不确定性的表示

□ 根据修改的贝叶斯公式可知:

➢ LS 越大, 则 $O(H|E)$ 越大, 且 $P(H|E)$ 也越大, 说明 E 对 H 的支持越强。当 $LS \rightarrow \infty$ 时, $O(H|E) \rightarrow \infty$, $P(H|E) \rightarrow 1$, 这说明 E 的存在导致 H 为真。因此说 E 对 H 是充分的, 且称 LS 为充分性因子。

➢ LN 反映了 $\sim E$ 的出现对 H 的支持程度。当 $LN=0$ 时, 将使 $O(H|\sim E)=0$, 这说明 E 的不存在导致 H 为假。因此说 E 对 H 是必要的, 且称 LN 为必要性因子。



43

2022/11/2

证据不确定性的表示

□ 采用概率形式表示证据的不确定性。例如对于初始证据 E , 用户根据观察 S 给出 $P(E|S)$, 它相当于动态强度。

□ 但由于难以给出 $P(E|S)$, 而在具体系统中往往采用适当的变通方法。例如, 在专家系统 PROSPECTOR 中, 让用户在 $-5 \sim 5$ 之间根据实际情况选一个数作为初始证据的可信度。

➢ $C(E|S) = -5$, $P(E|S) = 0$; $C(E|S) = 0$, $P(E|S) = P(E)$; $C(E|S) = 5$, $P(E|S) = 1$ 。

➢ 其他情况根据上述三种特例采用分段线性插值得到。




44

2022/11/2

证据不确定性的表示

□ 根据观察 S 给出可信度 $C(E|S)$ 来估计初始证据 E 的条件概率 $P(E|S)$ 。



45

2022/11/2

证据不确定性的表示

$$P(E|S) = \begin{cases} \frac{C(E|S) + P(E) \times (5 - C(E|S))}{5}, & 0 \leq C(E|S) \leq 5 \\ \frac{P(E) \times (C(E|S) + 5)}{5}, & -5 \leq C(E|S) \leq 0 \end{cases}$$

□ 只要用户对初始证据给出相应的可信度 $C(E|S)$, 系统就会把它转化为 $P(E|S)$, 也就相当于给出了证据 E 的概率 $P(E|S)$



46

2022/11/2

证据不确定性的表示

□ 当证据不确定时, 要用杜达等人证明的下列公式计算后验概率:

$$P(H|S) = P(H|E)P(E|S) + P(H|\sim E)P(\sim E|S)$$

➢ 当 $P(E|S) = 1$ 时, $P(\sim E|S) = 0$, $P(H|S) = P(H|E)$;

➢ 当 $P(E|S) = 0$ 时, $P(\sim E|S) = 1$, $P(H|S) = P(H|\sim E)$;

➢ 当 $P(E|S) = P(E)$ 时, $P(H|S) = P(H|E)P(E) + P(H|\sim E)P(\sim E) = P(H)$;

➢ 当 $P(E|S)$ 为其他值时, 通过分段线性插值计算 $P(H|S)$ 。



47

2022/11/2

证据不确定性的表示

□ 称为 EH 公式:

$$P(H|S) = \begin{cases} P(H|\sim E) + \frac{P(H) - P(H|\sim E)}{P(E)} P(E|S), & 0 \leq P(E|S) \leq P(E) \\ P(H) + \frac{P(H|E) - P(H)}{1 - P(E)} [P(E|S) - P(E)], & P(E) \leq P(E|S) \leq 1 \end{cases}$$

□ 将可信度 $C(E|S)$ 转化为 $P(E|S)$ 的公式代入 EH 公式, 得到 CP 公式:

$$P(H|S) = \begin{cases} P(H|\sim E) + [P(H) - P(H|\sim E)] \times \frac{1}{5} P(E|S) + 1], & C(E|S) \leq 0 \\ P(H) + [P(H|E) - P(H)] \times \frac{1}{5} C(E|S), & C(E|S) > 0 \end{cases}$$



48

2022/11/2

主观贝叶斯方法的推理过程

- 若采用初始证据进行推理，则通过用户得到C(E|S)，从而根据CP公式可求得P(H|S)。
- 若采用推理过程中得到的中间结论作为证据进行推理，则通过 EH 公式可求得P(H|S)。
- 如果有n条知识支持同一结论H,而且每一条知识的前提分别是n个相互独立的证据E₁, E₂, ..., E_n, 而这些证据又分别与观察 S₁, S₂, ..., S_n对应, 这时, 应首先对每条知识分别求出的后验几率O(H|S_i) , 然后按下述公式求出所有观察下的后验几率:

$$O(H | S_1, S_2, \dots S_n) = \frac{O(H | S_1)}{O(H)} \times \frac{O(H | S_2)}{O(H)} \times \dots \times \frac{O(H | S_n)}{O(H)} \times O(H)$$



主观贝叶斯方法的优缺点

- 计算公式具有比较坚实的理论基础;
- 规则中的LS, LN来自领域专家的实践经验, 且较全面地反映了证据与结论间的因果关系。
- 同时给出了证据确定与证据不确定情况下推理方法。
- ◆ 给出规则的同时, 需要给出H的先验概率P(H), 这是比较困难的。
- ◆ 贝叶斯定理中关于事件间独立性的要求使主观贝叶斯方法的应用受到一定限制。

