



本章内容

1. 计算智能
2. 神经计算
3. 模糊计算
4. 进化算法与遗传算法
5. 粒群优化算法
6. 蚁群算法

南昌大学 3 2023/1/31

本章内容

1. 计算智能
2. 神经计算
3. 模糊计算
4. 进化算法与遗传算法
5. 粒群优化算法
6. 蚁群算法

南昌大学 4 2023/1/31

概述

- 现代科学技术发展的一个显著特点就是信息科学与生命科学的**相互交叉、相互渗透和相互促进**，生物信息学就是两者结合而形成的新的交叉学科，**计算智能**则是另一个有说服力的示例。
- 计算智能涉及**神经计算、模糊计算、进化计算、粒群计算、蚁群算法、自然计算、免疫计算和人工生命等领域**，它的研究和发展正反映了当代科学技术多学科交叉与集成的重要发展趋势。

南昌大学 5 2023/1/31

概述

- 创造、发明和发现是千千万万科技开拓者的共同品性和永恒追求。包括牛顿、爱因斯坦、图灵和维纳等科学巨匠在内的科学家们，都致力于寻求与发现创造的技术和秩序。**人类的所有发明，几乎都有它们的自然界配对象。**
- **原子能**的和平利用和军事应用与出现在星球上的**热核爆炸**相对应；**各种电子脉冲系统**则与**人类神经系统的脉冲调制**相似；**蝙蝠的声呐和海豚的发声**起到一种神秘电话的作用，启发人类发明了**声呐传感器和雷达**；**鸟类的飞行行为**激发了人类飞天的梦想，发明了**飞机和飞船**，实现了空中和宇宙飞行。
- 科学家和工程师们应用数学和科学来**模仿自然、扩展自然**。人类智能已激励出高级计算、学习方法和技术。毫无疑问，智能是可达的，其证据就在我们眼前，就发生在日常工作和生活中。

南昌大学 6 2023/1/31

何为计算智能？

- **计算智能 (Computational Intelligence, CI)** 目前还没有一个统一的定义，使用较多的是美国科学家 J. C. Bezdek 从计算智能系统角度所给出的定义：
 - 如果一个系统**仅处理低层的数值数据**，
 - 含有**模式识别部件**，
 - **没有使用人工智能意义上的知识**，
 - 且具有**计算适应性、计算容错力、接近人的计算速度和近似于人的误差率**这4个特性，则它是计算智能的。



贝兹德克 (J.C. Bezdek)

南昌大学 7 2023/1/31

何为计算智能？

□ 从学科范畴看，计算智能是在神经网络（Neural Networks, NN）、进化计算（Evolutionary Computation, EC）以及模糊系统（Fuzzy System, FS）这三个领域发展相对成熟的基础上形成的一个统一的学科概念。



何为计算智能？

- 神经网络是一种对人类智能的**结构模拟方法**，它是通过对大量人工神经元的广泛并行互联，构造人工神经网络系统去模拟生物神经系统的智能机理的。
- 进化计算是一种对人类智能的**演化模拟方法**，它是通过对生物遗传和演化过程的认识，用进化算法去模拟人类智能的进化规律的。
- 模糊计算是一种对人类智能的**逻辑模拟方法**，它是通过对人类处理模糊现象的认知能力的认识，用模糊逻辑去模拟人类的智能行为的。



何为计算智能？

- 从Bezdek对计算智能的定义以及前述计算智能学科范畴的分析，可以看出以下两点：
 - 第一，计算智能是借鉴仿生学的思想，基于生物神经系统的结构、进化和认知对自然智能进行模拟的。
 - 第二，计算智能是一种以模型（计算模型、数学模型）为基础，以分布、并行计算为特征的自然智能模拟方法。



计算智能的产生与发展

- 1992年，Bezdek在《Approximate Reasoning》学报上首次提出了“计算智能”的概念。
- 1994年6月底到7月初，IEEE在美国佛罗里达州的奥兰多市召开了首届国际计算智能大会(简称WCCI'94)。会议第一次将神经网络、进化计算和模糊系统这三个领域合并在一起，形成了“计算智能”这个统一的学科范畴。



计算智能的产生与发展

- 在此之后，WCCI大会就成了IEEE的一个系列性学术会议，每4年举办一次。1998年5月，在美国阿拉斯加州的安克雷奇市召开了第2届计算智能国际会议WCCI'98。2002年5月，IEEE在美国夏威夷州首府火奴鲁鲁市又召开了第3届计算智能国际会议WCCI'02。此外，IEEE还出版了一些与计算智能有关的刊物。
- 当前，计算智能的发展得到了国内外众多的学术组织和研究机构的高度重视，并已成为智能科学技术一个重要的研究领域。




计算智能与人工智能的关系

- 目前，对CI与AI的关系有2种不同观点：
 - 一种观点认为CI是AI的一个子集（J. C. Bezdek）。
 - 另一种观点认为CI和AI是不同的范畴（CI构成了AI的一个不同选择，R. C. Eberhart）。
 - 目标相近
 - CI深入系统的核心
 - AI位于系统的外层




计算智能与人工智能的关系

□ Bezdek把智能 (Intelligence, I) 和神经网络 (Neural Network, NN) 都分为人工的 (Artificial, A)、生物的 (Biological, B) 和计算的 (Computational, C) 3个层次, 并以模式识别 (PR) 为例, 给出了下图所示的智慧的层次结构。




计算智能与人工智能的关系

□ 在该图中, 底层是计算智能 (CI), 它通过数值计算来实现, 其基础是CNN; 中间层是人工智能 (AI), 它通过人造的符号系统实现, 其基础是ANN; 顶层是生物智能 (BI), 它通过生物神经网络来实现, 其基础是BNN。



计算智能与人工智能的关系

□ 按照Bezdek的观点, CNN是指按生物激励模型构造的NN, ANN是指CNN+知识, BNN是指人脑, 即ANN包含了CNN, BNN又包含了ANN。对智能也一样, Bezdek认为AI包含了CI, BI又包含了AI, 即计算智能是人工智能的一个子集。



计算智能与人工智能的关系

□ 第二种观点是大多数学者所持有的观点, 其代表人物是Eberhart。他们认为: 虽然人工智能与计算智能之间有重合, 但计算智能是一个全新的学科领域, 无论是生物智能还是机器智能, **计算智能都是其最核心的部分, 而人工智能则是外层。**

□ 事实上, **C和传统的AI只是智能的两个不同层次**, 各自都有自身的优势和局限性, 相互之间只应该互补, 而不能取代。

□ 大量实践证明, 只有把**AI和C很好地结合起来**, 才能更好地模拟人类智能, 才是智能科学技术发展的正确方向。

本章内容

1. 计算智能
2. 神经计算
3. 模糊计算
4. 进化算法与遗传算法
5. 粒群优化算法
6. 蚁群算法

概述

□ As you read these words you are using a complex **biological neural network**. You have a highly interconnected set of **10¹¹** neurons to facilitate your reading, breathing, motion and thinking.

□ 人工神经网络是一种模仿生物神经网络的结构和功能的数学模型或计算模型。它是对人脑神经系统的简化、抽象和模拟, 具有人脑功能的许多基本特征。

人工神经网络的发展

- McCulloch & Pitts (1943) 被公认为第一个人工神经网络的设计者 (MP model)
 - 他们使用阈值以及用多个简单单元结合在一起以提高计算能力的思想到今天仍被广泛使用。
- 试图通过用计算模型模拟生物神经系统的方法来理解生物系统的工作模式。
- 高度的并行性使得其计算效率非常高。
- 有助于理解神经表示的“分布式”特征。



麦克洛奇



皮茨



20

2023/1/31

人工神经网络的发展

- 1949年Hebb提出了第一个神经网络的学习规则。
- 1958年Rosenblatt提出感知器 (perceptron) 模型, 1950's 和1960's, 许多研究者致力于研究该模型。
- 1969年 Minsky和Papert展示了感知器模型的局限性, 从此神经网络的研究陷入低潮, 沉寂了大概15年。
- 1980's, 神经网络重新成为研究热点
 - 1982 Hopfield: 递归神经网络(recurrent network model, RNN)
 - 1982 Kohonen: 自组织神经网络(self-organizing maps, SOFM)
 - 1986 Rumelhart: 反向传播网络(back propagation)




21

2023/1/31

生物神经系统简介

- 生物神经元的结构、生物神经元的功能、人脑神经系统的联结机制
- 生物神经元的结构: 它由细胞体(Soma)、轴突(Axon)和树突(Dendrite)三个主要部分组成。




22

2023/1/31

生物神经元的结构

- 树突是指由细胞体向外延伸的除轴突以外的其它所有分支。其长度一般较短, 但数量很多, 它是神经元的输入端, 用于接受从其它神经元的突触传来的信号。




23

2023/1/31

生物神经元的结构

- 细胞体由细胞核、细胞质和细胞膜等组成, 其直径大约为0.5-100μm大小不等。细胞体是神经元的主体, 用于处理由树突接受的其它神经元传来的信号, 其内部是细胞核, 外部是细胞膜, 细胞膜的外面是许多向外延伸出的纤维。




24

2023/1/31

生物神经元的结构

- 轴突是由细胞体向外延伸出的所有纤维中最长的一条分枝, 用来向外传递神经元产生的输出电信号。每个神经元都有一条轴突, 其最大长度可达1m以上。在轴突的末端形成了许多很细的分枝, 这些分支叫神经末梢。




25

2023/1/31

生物神经元的结构

- 每一条神经末梢可以与其它神经元形成功能性接触，该接触部位称为**突触**。所谓功能性接触，是指非永久性的接触，这正是神经元之间传递信息的奥秘之处。



生物神经元的功能


- 根据神经生理学的研究，生物神经元的2个主要功能是：

- **神经元的兴奋与抑制**：抑制状态是指神经元在没有产生冲动时的工作状态；兴奋状态是指神经元产生冲动时的工作状态。
- **神经元内神经冲动的传导**：神经冲动在神经元内的传导是一种电传导过程，神经冲动沿神经纤维传导的速度却在3.2~320km/s之间，且其传导速度与纤维的粗细、髓鞘的有无有一定关系。一般来说，有髓鞘的纤维的传导速度较快，而无髓鞘的纤维的传导速度较慢。

生物神经元的功能

- 神经元的兴奋与抑制

- 神经元细胞膜内外之间存在电位差，称为**膜电位**。膜外为正，膜内为负。
- 当神经元受到外部刺激时，其膜电位随之发生变化，**当膜内外的电位差大于阈值电位时**，神经元产生冲动而进入兴奋状态。



- 动作电位 $\approx 100\text{mV}$ • 持续时间 $\approx 1-2\text{ms}$
- 阈值电位 $\approx 20-30\text{mV}$ • 抑制时间 $\approx 10-20\text{ms}$
- 休息电位 $\approx -65\text{mV}$

生物神经元的功能

- 神经元的兴奋与抑制

- 神经元每次冲动的持续时间大约1毫秒左右，在此期间即使刺激强度再增加也不会引起冲动强度的增加。
- 神经元每次冲动结束后，都会重新回到抑制状态。
- 如果神经元受到的刺激作用不能使细胞膜内外的电位差大于阈值电位，则神经元不会产生冲动，将仍处于抑制状态。

人脑神经系统的联结机制

- 人脑神经系统的联结规模

- 人脑大约由 $10^{11} \sim 10^{12}$ 个神经元所组成，其中每个神经元大约有 3×10^4 个突触。
- 小脑中的每个神经元大约有 10^5 个突触，并且每个突触都可以与别的神经元的一个树突相连。
- 人脑神经系统就是由这些巨量的生物神经元广泛并行互连所形成的一个高度并行性、非常复杂的神经网络系统。


人脑神经系统的联结机制

- 人脑神经系统的分布功能

- 人脑神经系统的**记忆和处理功能是有机的结合在一起的**，每个神经元既具有存储功能，同时又具有处理能力。
- 从结构上看，**人脑神经系统又是一种分布式系统**。人们通过对脑损坏病人所做的神经生理学研究，没有发现大脑中的哪一部分可以决定其余所有各部分的活动，也没有发现在大脑中存在有用于驱动和管理整个智能处理过程的任何中央控制部分。
- 即，人类大脑的各个部分是**协同工作、相互影响**的。在大脑中，不仅知识的存储是分散的，而且其控制和决策也是分散的。

人脑神经系统的联结机制

- 突触会根据经验改变自己的大小和连接强度。



人脑神经系统的联结机制

- 神经网络的学习过程最终是发生在神经元之间的突触部位，突触的联结强度随着突触前后神经元的活动而变化，变化的量与两个神经元的活性之和成正比。——Hebb 《行为自组织》
- Hebb规则意义（提出了变化的概念）：
 - 神经网络里的信息是储藏在突触连接权中的。
 - 连接权的学习律正比于两个被连接神经细胞的活动状态值的乘积。
 - 细胞的互联结构是他们权的改变创造出来的。

人工神经网络简介

- 人工神经网络是由大量的人工神经元广泛互联所形成的一种人工网络系统，用以模拟人类神经系统的结构和功能。


- 人工神经元的结构
- 常用的人工神经元模型

人工神经元的结构

- 神经元单元由多个输入 x_i , $i=1, 2, \dots, n$ 和一个输出 y 组成。中间状态由输入信号的权和表示，而输出为


$$y = f\left(\sum_{i=1}^n w_i x_i - \theta\right)$$

式中， θ 为神经单元的阈值（或偏置）， w_i 为连接权系数， $f(\cdot)$ 为输出变换函数（或称作激活函数）。



人工神经元的结构

- 可将阈值 θ 看作为权重，此时其对应的输入为常量1




$$\begin{cases} net = \sum_{i=1}^n w_i x_i \\ y = f(net - \theta) \end{cases}$$

$$\begin{cases} net = b + \sum_{i=1}^n w_i x_i = \sum_{i=0}^n w_i x_i \\ y = f(net) \end{cases}$$

人工神经元的结构

- 若不需要时，阈值 b 可省略。
- 阈值 b 和权重 w_i 是可调节的标量。
- 可根据某些学习规则来调节阈值和权重，使得神经元的输入输出关系满足某些特定的目标。




$$\begin{cases} net = b + \sum_{i=1}^n w_i x_i = \sum_{i=0}^n w_i x_i \\ y = f(net) \end{cases}$$

常用的人工神经元模型


□ 根据激活函数的不同，可得到不同的神经元模型。比如：

- 阈值型(Threshold)：这种模型没有内部状态，激活函数是一个阶跃函数。
- 分段线性强饱和型(Linear Saturation)：这种模型又称为伪线性，其输入/输出之间在一定范围内满足线性关系，一直延续到输出为最大值1为止。但当达到最大值后，输出就不再增大。



常用的人工神经元模型

- S型(Sigmoid)：这是一种连续的神经元模型，其输入输出特性常用指数、对数或双曲正切等S型函数表示。
- 修正线性单元(Rectified Linear Unit, ReLU)：这种模型其实是一个分段线性函数，把所有的负值都变为0，而正值不变，这种操作被称为单侧抑制。



人工神经网络的互连结构

□ 人工神经网络是具有下列特性的有向图：

- 对于每个节点 i 存在一个状态变量 x_i ；
- 从节点 i 至节点 j ，存在一个连接权系数 w_{ij} ；
- 对于每个节点 i ，存在一个阈值 θ_i ；
- 对于每个节点 j ，定义一个变换函数 $f_j(x_j, w_{ij}, \theta_j)$, $i \neq j$ ；对于最一般的情况，此函数取 $f_j(\sum_i w_{ij}x_i - \theta_j)$ 形式。

人工神经网络的互连结构

□ 人工神经网络的互连结构(或称拓扑结构)是指单个神经元之间的连接模式，它是构造神经网络的基础，也是神经网络诱发偏差的主要来源。从互连结构的角：



前馈网络

□ 前馈网络包括**单层前馈网络**和**多层前馈网络**。

□ 单层前馈网络是指那种只拥有单层计算节点的前向网络。它仅含有输入层和输出层，且只有输出层的神经元是可计算节点，如下图所示：



前馈网络

□ 若假设各神经元的阈值分别是 θ_j ($j=1, 2, \dots, m$)，则各神经元的输出 y_j ($j=1, 2, \dots, m$) 分别为：

$$y_j = f_j\left(\sum_i w_{ij}x_i - \theta_j\right)$$


其中，由所有连接权值 w_{ij} 构成的连接权值矩阵 $\mathbf{W}$ 为：

$$\mathbf{W} = \begin{bmatrix} w_{11} & w_{12} & \dots & w_{1m} \\ w_{21} & w_{22} & \dots & w_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & \dots & w_{nm} \end{bmatrix}$$

在实际应用中，该矩阵是通过大量的训练示例学习而形成的。


前馈网络

□ 多层前馈网络是指那种除拥有输入、输出层外，还至少含有一个、或更多个隐含层的前馈网络。




前馈网络

□ 隐含层是指由那些既不属于输入层又不属于输出层的神经元所构成的处理层，也被称为**中间层**。隐含层的作用是通过输入层信号的加权处理，将其转移成更能被输出层接受的形式。



前馈网络


□ 多层前馈网络的输入层的输出向量是第一隐含层的输入信号，而第一隐含层的输出则是第二隐含层的输入信号，以此类推，直到输出层。（多层前馈网络的典型代表是BP网络）



反馈网络

□ 反馈网络（又称递归网络，Recursive (feedback) network）是指允许采用反馈连接方式所形成的神经网络。

□ 所谓反馈连接方式是指一个神经元的输出可以被反馈至同层或前层的神经元。（反馈网络的典型代表是Hopfield网络）



反馈网络

□ 反馈网络和前馈网络的区别：

- 前向网络属于非循环连接模式，它的每个神经元的输入都没有包含该神经元先前的输出，因此不具有“短期记忆”的性质。
- 反馈网络则不同，它的每个神经元的输入都有可能包含有该神经元先前输出的反馈信息，即一个神经元的输出是由该神经元当前的输入和先前的输出这两者来决定的，这就有点类似于人类的短期记忆的性质。

人工神经网络的典型模型

□ 人工神经网络的模型是指对网络结构、联结权值和学习能力的总括。

□ 常用的网络模型已有数十种。例如：

- 传统的感知机模型。
- 具有误差反向传播功能的反向传播网络模型。
- 采用反馈联接方式的反馈网络模型。

感知器模型

□ 感知器是美国学者罗森勃拉特 (Rosenblatt) 于1957年为研究大脑的存储、学习和认知过程而提出的一类具有自学习能力的神经网络模型，其拓扑结构是一种分层前向网络。

□ 感知器包括：

➢ 单层感知器

➢ 多层感知器



50

2023/1/31

感知器模型

□ 单层感知器

➢ 单层感知器是一种只具有单层可调节连接权值神经元的前向网络，这些神经元构成了单层感知器的输出层，是感知器的可计算节点。

➢ 在单层感知器中，每个可计算节点都是一个线性阈值神经元。当输入信息的加权和大于或等于阈值时，输出为1，否则输出为0或-1。

➢ 单层感知器的输出层的每个神经元都只有一个输出，且该输出仅与本神经元的输入及联接权值有关，而与其他神经元无关。



51

2023/1/31

感知器模型

□ 单层感知器

➢ 使用感知器的主要目的是为了对外部输入进行分类。罗森勃拉特已经证明，如果外部输入是线性可分的（指存在一个超平面可以将它们分开），则单层感知器一定能够把它划分为两类。




52

2023/1/31

感知器模型

□ AND

input		output	function	condition
x_1	x_2	$x_1 \wedge x_2$	$w_1 * x_1 + w_2 * x_2 - T = 0$	
0	0	0	$w_1 * 0 + w_2 * 0 - T < 0$	$T > 0$
0	1	0	$w_1 * 0 + w_2 * 1 - T < 0$	$T > w_2$
1	0	0	$w_1 * 1 + w_2 * 0 - T < 0$	$T > w_1$
1	1	1	$w_1 * 1 + w_2 * 1 - T \geq 0$	$T \leq w_1 + w_2$




53

2023/1/31

感知器模型

□ OR

input		output	function	condition
x_1	x_2	$x_1 \vee x_2$	$w_1 * x_1 + w_2 * x_2 - T = 0$	
0	0	0	$w_1 * 0 + w_2 * 0 - T < 0$	$T > 0$
0	1	1	$w_1 * 0 + w_2 * 1 - T \geq 0$	$T \leq w_2$
1	0	1	$w_1 * 1 + w_2 * 0 - T \geq 0$	$T \leq w_1$
1	1	1	$w_1 * 1 + w_2 * 1 - T \geq 0$	$T \leq w_1 + w_2$




54

2023/1/31

感知器模型

□ NOT

input	output	function	condition
x_1	$\sim x_1$	$w_1 * x_1 - T = 0$	
0	1	$w_1 * 0 - T \geq 0$	$T \leq 0$
1	0	$w_1 * 1 - T < 0$	$T > w_1$



Let threshold be 0, single input with a negative weight



55


2023/1/31

感知器模型

□ 单层感知器

> 1969年, Minsky和Papert合作发表了颇有影响的Perceptron一书, 分析了很多感知器无法解决的问题, 得出了消极悲观的论点。指出感知器无法解决线性不可分问题。

input		output
x_1	x_2	$x_1 \text{ xor } x_2$
0	0	0
0	1	1
1	0	1
1	1	0




感知器模型

□ 单层感知器

> 异或不是线性可分逻辑, 无法通过单层Perceptron实现。


> 解决思路:
通过多个神经元互联成网络, 形成多条直线对平面上的点进行分类。(利用多层感知机实现)



感知器模型

□ 多层感知器

> 多层感知器是通过在单层感知器的输入、输出层之间加入一层或多层处理单元所构成的。



感知器模型

□ 多层感知器



> 多层感知器的输入与输出之间是一种高度非线性的映射关系。

> 若采用多层感知器模型, 则该网络就是一个从n维欧氏空间到m维欧氏空间的非线性映射。

> 因此, 多层感知器可以实现非线性可分问题的分类。例如, 对“异或”运算, 用多层感知器即可解决。

感知器模型


□ 多层感知器



感知器模型

□ 多层感知器


> 输出层神经元所确定的直线方程相当于对隐层神经元 h_1 和 h_2 的输出作“逻辑与”运算, 因此可识别由隐层已识别的两个半平面的交集所构成的一个凸多边形。



感知器模型

□ 多层感知器

input		output
x_1	x_2	$x_1 \text{ xor } x_2$
0	0	0
0	1	1
1	0	1
1	1	0



BP神经网络模型

- 误差反向传播(Error Back Propagation)网络通常简称为BP(Back Propagation)网络, 是由美国加州大学的鲁梅尔哈特和麦克莱兰在研究并行分布式信息处理方法, 探索人类认知微结构的过程中, 于1985年提出的一种网络模型。
- BP网络的网络拓扑结构是多层前馈网络。在BP网络中, 同层节点之间不存在相互连接, 层与层之间多采用全互连方式, 且各层的连接权值可调。BP网络实现了明斯基的多层网络的设想, 是当今神经网络模型中使用最广泛的一种。



BP神经网络模型

□ 对BP网络需说明以下两点:

- BP网络的每个处理单元均为非线性输入/输出关系, 其作用函数通常采用的是可微的Sigmoid函数, 如: $f(x) = 1/(1 + \exp(-x))$
- BP网络的学习过程是由工作信号的正向传播和误差信号的反向传播组成的。所谓正向传播, 是指输入模式经隐层到输出层, 最后形成输出模式; 所谓误差反向传播, 是指从输出层开始逐层将误差传到输入层, 并修改各层联接权值, 使误差信号为最小的过程。

Hopfield网络模型

- Hopfield网络是由美国加州理工学院物理学家Hopfield于1982年提出的一种单层全互连的对称反馈网络模型。Hopfield网络可以作为联想存储器, 因此又称为联想记忆网络。它可分为离散Hopfield网络和连续Hopfield网络, 这里简要讨论离散Hopfield网络。



Hopfield

Hopfield网络模型


- 离散Hopfield网络模型是一个离散时间系统, 每个神经元只有0和1 (或-1和1) 两种状态, 任意神经元*i*和*j*之间的连接权值为 w_{ij} 。由于神经元之间为对称连接, 且神经元自身无连接, 因此有:

$$w_{ij} = \begin{cases} w_{ji} & \text{if } i \neq j \\ 0 & \text{if } i = j \end{cases}$$

由该连接权值所构成的连接矩阵是一个零对角的对称矩阵。

Hopfield网络模型

- 在 Hopfield网络中, 虽然神经元自身无连接, 但由于每个神经元都与其他神经元相连, 同时每个神经元又都接受其他神经元传来的信息, 这样对每个神经元来说, 其输出经过其他神经元后又有可能反馈给自己, 因此Hopfield网络是一种反馈神经网络。



Hopfield网络模型

- 假设共有 N 个神经元，每个神经元 i 时刻的输入为 x_i ，二值化后的输出为 y_i ，则 t 时刻神经元的输入为：

$$x_i = \sum_{j=1, j \neq i}^N w_{ij} y_j + b_i$$

- b_i 是第 i 个神经元的偏置量。 $t+1$ 时刻的输出为：

$$y_i(t+1) = f(x_i(t))$$



68

2023/1/31

Hopfield网络模型

- Hopfield网络按神经动力学的方式运行，工作过程为状态的演化过程，对于给定的初始状态，按“能量”减小的方式演化，最终达到稳定状态。
- 对于反馈网络来说，稳定性是至关重要的性质，但反馈网络不一定都能稳定收敛。网络从初态 $Y(0)$ 开始，经过有限次递归之后，如果其状态不再发生变化，即 $Y(t+1)=Y(t)$ ，则称该网络是稳定的。



69

2023/1/31

Hopfield网络模型

- 不稳定的网络往往是发散到无穷远的系统，在离散Hopfield网络中，由于输出只能取二值化的值，因此不会出现无穷大的情况，此时，网络出现有限幅度的自持震荡，在有限个状态中反复循环，称为**有限环网络**。
- 在有限环网络中，系统在确定的几个状态中循环往复。系统也可能不稳定收敛于一个确定状态，而是在无限多个状态之间变化，但轨迹并不发散到无穷远，这种现象称为**混沌**。



70

2023/1/31

神经网络的主要学习算法


- Supervised learning algorithms（有师学习）：能够根据期望的和实际的网络输出（对应于给定输入）间的差来调整神经元间连接的强度或权。
- Unsupervised learning algorithms（无师学习）：不需要知道期望输出。
- Reinforcement learning algorithms（增强学习）：采用一个“评论员”来评价与给定输入相对应的神经网络输出的优劣（质量因数）。强化学习算法的一个例子是遗传算法（GA）。



71

2023/1/31

神经网络的应用举例



72

2023/1/31

神经网络的应用举例

- Shape sensor: 1 -- round, -1 -- elliptical.
- Texture sensor: 1 -- smooth, -1 -- rough.
- Weight sensor: 1 -- > 1 pound, -1 -- < 1 pound.

$$\mathbf{p} = \begin{bmatrix} \text{shape} \\ \text{texture} \\ \text{weight} \end{bmatrix} \Rightarrow \mathbf{p}(\text{apple}) = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}, \quad \mathbf{p}(\text{orange}) = \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix}$$



73

2023/1/31

神经网络的应用举例

$$\mathbf{p} = \begin{bmatrix} \text{shape} \\ \text{texture} \\ \text{weight} \end{bmatrix} \Rightarrow \text{three-dimensional input } (R=3)$$

$$n = \mathbf{W}\mathbf{p} + b, \quad a = \text{hardlims}(n)$$

Choose the **bias** b and the elements of the **weight matrix** $\mathbf{W}$ so that the perceptron will can distinguish between **apples** and **oranges**.



74

2023/1/31

神经网络的应用举例

$$\mathbf{p}(\text{apple}) = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}, \quad \mathbf{p}(\text{orange}) = \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} \Rightarrow \mathbf{W} = \begin{bmatrix} 0 & 1 & 0 \end{bmatrix}, \quad b = 0$$

$$\text{Orange: } a = \text{hardlims} \left(\begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} + 0 \right) = -1$$

$$\text{Apple: } a = \text{hardlims} \left(\begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix} + 0 \right) = 1$$



75

2023/1/31

神经网络的应用举例

□ What happens if we put a **not-so-perfect orange** into the classifier? That is to say, an orange with an **elliptical shape** is pass through the sensor.

$$\mathbf{p} = \begin{bmatrix} \text{shape} \\ \text{texture} \\ \text{weight} \end{bmatrix} \Rightarrow \mathbf{p}(\text{orange}) = \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} \Rightarrow \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix}$$

$$a = \text{hardlims} \left(\begin{bmatrix} 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix} + 0 \right) = -1 \Rightarrow \text{orange}$$



76

2023/1/31