

第 3 章 线性方程组的数值解法

本章主要内容：

- (1) Gauss 消去法, Gauss 列主元消去法
- (2) 方程组的性态和误差估计
- (3) 迭代法 (Jacobi、Gauss-Seidel、SOR 迭代)
- (4) 幂法和反幂法

1 Gauss 消去法

思想：利用线性代数中的初等行变换将方程组化为等价的三角形方程组.

1.1 三角形方程组的回代法

考虑三角形方程组

$$\begin{aligned} u_{11}x_1 + u_{12}x_2 + \cdots + u_{1,n-1}x_{n-1} + u_{1n}x_n &= y_1 \\ u_{22}x_2 + \cdots + u_{2,n-1}x_{n-1} + u_{2n}x_n &= y_2 \\ \cdots &\cdots \\ u_{n-1,n-1}x_{n-1} + u_{n-1,n}x_n &= y_{n-1} \\ u_{nn}x_n &= y_n \end{aligned}$$

其中 $u_{ii} \neq 0 (i = 1, 2, \cdots, n)$. 用下面的回代法求解:

$$\begin{cases} x_n = y_n / u_{nn}, \\ x_i = \left(y_i - \sum_{j=i+1}^n u_{ij}x_j \right) / u_{ii}, \quad i = n-1, n-2, \cdots, 1. \end{cases}$$

1.2 Gauss 消去法

考虑一般的线性方程组

$$\mathbf{Ax} = \mathbf{b}, \quad (1.1)$$

其中

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

将方程 $\mathbf{Ax} = \mathbf{b}$ 用增广矩阵表示, 记

$$\bar{\mathbf{A}}^{(1)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ a_{21}^{(1)} & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} & a_{2,n+1}^{(1)} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1}^{(1)} & a_{n2}^{(1)} & \cdots & a_{nn}^{(1)} & a_{n,n+1}^{(1)} \end{bmatrix},$$

$a_{21}^{(1)} - a_{11}^{(1)} \cdot \frac{a_{21}^{(1)}}{a_{11}^{(1)}}$
 $r_2 - r_1$

其中

$$a_{ij}^{(1)} = a_{ij}, \quad i, j = 1, 2, \cdots, n,$$

$$a_{i,n+1}^{(1)} = b_i, \quad i = 1, 2, \dots, n.$$

下面用 $n - 1$ 步消元 (初等行变换) 将矩阵 $\bar{\mathbf{A}}^{(1)}$ 化为上三角矩阵.

(1) 第 1 步消元: 假设 $a_{11}^{(1)} \neq 0$ (否则交换两行的位置), 记 $l_{i1} = \frac{a_{i1}^{(1)}}{a_{11}^{(1)}}$,

第 1 行乘 $-l_{i1}$ 加到第 i ($2 \leq i \leq n$) 行得

$$\bar{\mathbf{A}}^{(1)} \longrightarrow \bar{\mathbf{A}}^{(2)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & a_{n2}^{(2)} & \cdots & a_{nn}^{(2)} & a_{n,n+1}^{(2)} \end{bmatrix}$$

消元因子

$r_i - r_1 \cdot l_{i1}$

其中

$$a_{ij}^{(2)} = a_{ij}^{(1)} - l_{i1}a_{1j}^{(1)}, \quad i = 2, 3, \dots, n, \quad j = 2, 3, \dots, n + 1.$$

(2) 第 2 步消元: 假设 $a_{22}^{(2)} \neq 0$ (否则交换两行的位置), 记 $l_{i2} = \frac{a_{i2}^{(2)}}{a_{22}^{(2)}}$,

第 2 行乘 $-l_{i2}$ 加到第 i ($3 \leq i \leq n$) 行得

$$\bar{\mathbf{A}}^{(2)} \longrightarrow \bar{\mathbf{A}}^{(3)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & a_{3n}^{(3)} & \cdots & a_{nn}^{(3)} & a_{n,n+1}^{(3)} \end{bmatrix}$$

其中

$$a_{ij}^{(3)} = a_{ij}^{(2)} - l_{i2}a_{2j}^{(2)}, \quad i = 3, 4, \cdots, n, \quad j = 3, 4, \cdots, n+1.$$

(3) 假设按上面进行了 $k-1$ 步消元, 即有

$$\bar{\mathbf{A}}^{(1)} \longrightarrow \bar{\mathbf{A}}^{(2)} \longrightarrow \bar{\mathbf{A}}^{(3)} \longrightarrow \cdots \longrightarrow \bar{\mathbf{A}}^{(k)},$$

其中

$$\bar{\mathbf{A}}^{(k)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1,k-1}^{(1)} & a_{1k}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2,k-1}^{(2)} & a_{2k}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3,k-1}^{(3)} & a_{3k}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{k-1,k-1}^{(k-1)} & a_{k-1,k}^{(k-1)} & \cdots & a_{k-1,n}^{(k-1)} & a_{k-1,n+1}^{(k-1)} \\ 0 & 0 & 0 & \cdots & 0 & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} & a_{k,n+1}^{(k)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+1,k}^{(k)} & \cdots & a_{k+1,n}^{(k)} & a_{k+1,n+1}^{(k)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} & a_{n,n+1}^{(k)} \end{bmatrix}$$

Red annotations in the image: A red circle highlights the submatrix starting from row k and column k to row n and column n . A red arrow points to the element $a_{kk}^{(k)}$ with the text $\neq 0$, indicating it is non-zero. A red wavy line is drawn under the first five columns of the matrix.

(4) 第 k 步消元: 假设 $a_{kk}^{(k)} \neq 0$ (否则交换两行的位置), 记 $l_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$, 第 k 行乘 $-l_{ik}$ 加到第 i ($k+1 \leq i \leq n$) 行得

$$\bar{A}^{(k)} \longrightarrow \bar{A}^{(k+1)}$$

$$= \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1,k}^{(1)} & a_{1,k+1}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2,k}^{(2)} & a_{2,k+1}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3,k}^{(3)} & a_{3,k+1}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{kk}^{(k)} & a_{k,k+1}^{(k)} & \cdots & a_{k,n}^{(k)} & a_{k,n+1}^{(k)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+1,k+1}^{(k+1)} & \cdots & a_{k+1,n}^{(k+1)} & a_{k+1,n+1}^{(k+1)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+2,k+1}^{(k+1)} & \cdots & a_{k+2,n}^{(k+1)} & a_{k+2,n+1}^{(k+1)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{n,k+1}^{(k+1)} & \cdots & a_{nn}^{(k+1)} & a_{n,n+1}^{(k+1)} \end{bmatrix}$$

其中

$$a_{ij}^{(k+1)} = a_{ij}^{(k)} - l_{ik}a_{kj}^{(k)},$$

$$i = k + 1, k + 2, \dots, n, \quad j = k + 1, k + 2, \dots, n + 1. \quad (1.2)$$

(5) 总共进行 $n - 1$ 步 ($k = 1, 2, \dots, n - 1$) 消元后,

$$\bar{\mathbf{A}}^{(1)} \longrightarrow \bar{\mathbf{A}}^{(2)} \longrightarrow \bar{\mathbf{A}}^{(3)} \longrightarrow \dots \longrightarrow \bar{\mathbf{A}}^{(k)} \longrightarrow \dots \longrightarrow \bar{\mathbf{A}}^{(n)},$$

其中

$$\bar{\mathbf{A}}^{(n)} = \left[\begin{array}{ccccc|c} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1,n-1}^{(1)} & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2,n-1}^{(2)} & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ & & \ddots & \vdots & \vdots & \vdots \\ & & & a_{n-1,n-1}^{(n-1)} & a_{n-1,n}^{(n-1)} & a_{n-1,n+1}^{(n-1)} \\ & & & & a_{nn}^{(n)} & a_{n,n+1}^{(n)} \end{array} \right]. \quad (1.3)$$

若记

$$U = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1,n-1}^{(1)} & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2,n-1}^{(2)} & a_{2n}^{(2)} \\ & & \ddots & \vdots & \vdots \\ & & & a_{n-1,n-1}^{(n-1)} & a_{n-1,n}^{(n-1)} \\ & & & & a_{nn}^{(n)} \end{bmatrix}, \quad y = \begin{bmatrix} a_{1,n+1}^{(1)} \\ a_{2,n+1}^{(2)} \\ \vdots \\ a_{n-1,n+1}^{(n-1)} \\ a_{n,n+1}^{(n)} \end{bmatrix},$$

则 (1.3) 对应的线性方程组为 $Ux = y$, 用回代可求得 x .

可以估计, Gauss 消元法解线性方程组 (1.1) 需要加法和乘法次数均为 $O(n^3)$.

定理 1.1 给定线性方程组 $Ax = b$. 如果 A 的各阶顺序主子式非零, 则 Gauss 消去法中的各主元 $a_{kk}^{(k)} (k = 1, 2, \dots, n)$ 均非零.

1.3 三对角方程组的追赶法

考虑三对角方程组

$$\begin{bmatrix} b_1 & c_1 & & & \\ \underline{a_2} & \underline{b_2} & c_2 & & \\ & \cancel{a_3} & \underline{b_3} & c_3 & \\ & & \dots & \dots & \dots \\ & & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & & \underline{a_n} & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_{n-1} \\ x_n \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_{n-1} \\ d_n \end{bmatrix} \quad (1.4)$$

其系数矩阵元素满足

- (1) $|b_1| > |c_1| > 0$;
- (2) $|b_i| \geq |a_i| + |c_i|, \quad \underline{a_i c_i \neq 0} (i = 2, 3, \dots, n-1)$;
- (3) $|b_n| > |a_n| > 0$.

易证 (1.4) 的系数矩阵非奇异. 利用 Gauss 消去法解方程组 (1.4), 每步消元只要消一个元素.

消元过程算法如下:

$$\beta_1 = b_1, \quad y_1 = d_1,$$

对 $i = 2, 3, \dots, n$ 计算

$$l_i = \frac{a_i}{\beta_{i-1}}, \quad \beta_i = b_i - l_i c_{i-1}, \quad y_i = d_i - l_i y_{i-1}.$$

回代算法:

$$x_n = y_n / \beta_n,$$

对 $i = n - 1, n - 2, \dots, 1$ 计算

$$x_i = (y_i - c_i x_{i+1}) / \beta_i.$$


1.4 列主元 Gauss 消去法

由 (1.2) 看出, 在 Gauss 消去法中, 当 $|l_{ik}|$ 很大 (如 $|a_{kk}^{(k)}|$ 很小) 时, 元素 $a_{kj}^{(k)}$ 很小的误差, 将导致元素 $a_{ij}^{(k+1)}$ 较大的误差. 所以希望 $|l_{ik}| \leq 1$. 设进行了 $k-1$ 步消元.

$$\bar{A}^{(k)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1,k-1}^{(1)} & a_{1k}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2,k-1}^{(2)} & a_{2k}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3,k-1}^{(3)} & a_{3k}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{k-1,k-1}^{(k-1)} & a_{k-1,k}^{(k-1)} & \cdots & a_{k-1,n}^{(k-1)} & a_{k-1,n+1}^{(k-1)} \\ 0 & 0 & 0 & \cdots & 0 & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} & a_{k,n+1}^{(k)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+1,k}^{(k)} & \cdots & a_{k+1,n}^{(k)} & a_{k+1,n+1}^{(k)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & a_{ik}^{(k)} & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} & a_{n,n+1}^{(k)} \end{bmatrix}$$

$\downarrow k$

在第 k 步消元之前, 从第 k 列位于对角线以下的元素中选绝对值最大

者作为主元. 如果

$$|a_{sk}^{(k)}| = \max_{k \leq i < n} |a_{ik}^{(k)}|,$$

即 (s, k) 元素绝对值最大, 则交换第 s 行和第 k 行对应元素, 然后进行消元. 显然此时有

$$|l_{ik}| = \left| \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}} \right| \leq 1.$$

例 1.1 用列主元 Gauss 消去法求下列方程组的解.

$$\begin{bmatrix} 3 & 1 & -1 \\ 4 & 0 & 4 \\ 12 & -3 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 8 \\ 9 \end{bmatrix}.$$

$$\underline{x^T A x > 0},$$

2 方程组的性态与误差分析

2.1 向量范数

设 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbf{R}^n$.

定义 2.1 设 $f(\mathbf{x}) = \|\mathbf{x}\|$ 是 $\mathbf{R}^n$ 上的函数, 如果满足

(1) (非负性) $\forall \mathbf{x} \in \mathbf{R}^n$, 有 $\|\mathbf{x}\| \geq 0$, 且 $\|\mathbf{x}\| = 0 \Leftrightarrow \mathbf{x} = \mathbf{0}$;

(2) (齐次性) $\forall \mathbf{x} \in \mathbf{R}^n, \lambda \in \mathbf{R}$, 有 $\|\lambda \mathbf{x}\| = |\lambda| \|\mathbf{x}\|$;

(3) (三角不等式) $\forall \mathbf{x}, \mathbf{y} \in \mathbf{R}^n$, 有 $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$.

则称 $\|\cdot\|$ 为 $\mathbf{R}^n$ 上的向量范数

注 2.1 用 $\mathbf{C}^n$ 表示所有复的 n 维向量组成的复线性空间, 类似可以定义对应的向量范数.

常用的三个向量范数:

(1) 1-范数: $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$;

(2) ∞ -范数: $\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} \{|x_i|\}$;

$$f: \mathbf{R}^n \rightarrow \mathbf{R}^1 (>0)$$

$$\mathbf{R} + \mathbf{U} \{0\}$$

$$C_1 \|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_1 \leq C_2 \|\mathbf{x}\|_\infty$$
$$C_1 = 1$$
$$C_2 = n$$

(3) 2-范数: $\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{\mathbf{x}^T \mathbf{x}} = \sqrt{(\mathbf{x}, \mathbf{x})}.$

由范数定义的三角不等式易得

$$|\|\mathbf{x}\| - \|\mathbf{y}\|| \leq \|\mathbf{x} - \mathbf{y}\|.$$

定理 2.1 (向量范数的连续性) 设 $f(\mathbf{x}) = \|\mathbf{x}\|$ 为 $\mathbf{R}^n$ 上的任意一个向量范数, 则 $f(\mathbf{x})$ 为 $\mathbf{x}$ 分量的连续函数. 即

$$\lim_{\mathbf{x} \rightarrow \mathbf{y}} f(\mathbf{x}) = f(\mathbf{y}).$$

定义 2.2 设 $\|\cdot\|_p$ 和 $\|\cdot\|_q$ 是 $\mathbf{R}^n$ 上两个范数. 如果存在正常数 c_1, c_2 使得对 $\forall \mathbf{x} \in \mathbf{R}^n$, 有

$$c_1 \|\mathbf{x}\|_p \leq \|\mathbf{x}\|_q \leq c_2 \|\mathbf{x}\|_p,$$

则称范数 $\|\cdot\|_p$ 和 $\|\cdot\|_q$ 等价.

定理 2.2 (向量范数的等价性) $\mathbf{R}^n$ 上任意两个范数都等价.

定义 2.3 设 $\|\cdot\|$ 是 $\mathbf{R}^n$ 上的范数, $\mathbf{x}, \mathbf{y} \in \mathbf{R}^n$, 称 $\|\mathbf{x} - \mathbf{y}\|$ 为 $\mathbf{x}$ 和 $\mathbf{y}$ 之间的距离.

利用距离可以研究 2 个向量之间的绝对误差和相对误差. 设 $\mathbf{x}^*$, $\tilde{\mathbf{x}}$ 是方程组 $A\mathbf{x} = b$ 的精确解和近似解. 则可用 $\|\mathbf{x}^* - \tilde{\mathbf{x}}\|$ 和 $\frac{\|\mathbf{x}^* - \tilde{\mathbf{x}}\|}{\|\mathbf{x}^*\|}$ 或 $\frac{\|\mathbf{x}^* - \tilde{\mathbf{x}}\|}{\|\tilde{\mathbf{x}}\|}$ 表示近似解 $\tilde{\mathbf{x}}$ 的绝对误差和相对误差.

定义 2.4 设 $\|\cdot\|$ 是 $\mathbf{R}^n$ 中的一个范数, $\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots$ 是 $\mathbf{R}^n$ 中的一个向量序列, $\mathbf{c} \in \mathbf{R}^n$ 为常向量. 如果

$$\lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{c}\| = 0,$$

则称向量序列 $\{\mathbf{x}^{(k)}\}_{k=0}^{\infty}$ 收敛于 $\mathbf{c}$, 记为

$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{c}.$$

2.2 矩阵范数

设

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix},$$

$j=1$
 $\sum |a_{ij}|$
 $\sum |a_{nj}|$
 $\sum |a_{ii}|$
 $\sum |a_{in}|$

$\|\cdot\|$ 为 $\mathbf{R}^n$ 上的一个范数.

定义 2.5 称

$$\max_{\substack{x \in \mathbf{R}^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|}$$

为矩阵 A 的范数, 记为 $\|A\|$. 即

$$\|A\| = \max_{\substack{x \in \mathbf{R}^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|}.$$

$= \max_{\|\tilde{x}\|=1, \tilde{x} \in \mathbf{R}^n} \|A\tilde{x}\|$
 $\|A\| \geq \frac{\|Ax\|}{\|x\|}$

问题: 最大值能否取到?

矩阵范数的性质: 设 $\|\cdot\|$ 是一个矩阵范数, 则有

(1) $\forall A \in \mathbf{R}^{n \times n}$, $\|A\| \geq 0$, 且 $\|A\| = 0 \Leftrightarrow A = 0$.

$$(2) \forall A \in \mathbf{R}^{n \times n}, \lambda \in \mathbf{R}, \text{ 有 } \|\lambda A\| = |\lambda| \|A\|.$$

$$(3) \forall A, B \in \mathbf{R}^{n \times n}, \text{ 有 } \|A + B\| \leq \|A\| + \|B\|.$$

$$(4) \forall A, B \in \mathbf{R}^{n \times n}, \text{ 有 } \|AB\| \leq \|A\| \|B\|.$$

$$(5) \forall A \in \mathbf{R}^{n \times n}, x \in \mathbf{R}^n, \text{ 有 } \|Ax\| \leq \|A\| \|x\|.$$

定义 2.6 设矩阵 $B \in \mathbf{R}^{n \times n}$, $\lambda_1, \lambda_2, \dots, \lambda_n$ 为 B 的 n 个特征值. 称

$$\rho(B) = \max_{1 \leq i \leq n} \{|\lambda_i|\}$$

为矩阵 B 的谱半径.

定理 2.3 设 $A \in \mathbf{R}^{n \times n}$, 则

(1)

$$\|A\|_1 = \max_{\substack{x \in \mathbf{R}^n \\ x \neq 0}} \frac{\|Ax\|_1}{\|x\|_1} = \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\}.$$

(2)

$$\|A\|_\infty = \max_{\substack{x \in \mathbf{R}^n \\ x \neq 0}} \frac{\|Ax\|_\infty}{\|x\|_\infty} = \max_{1 \leq i \leq n} \left\{ \sum_{j=1}^n |a_{ij}| \right\}.$$

λ_1, x_1
492c
10号.

$$Bx = \lambda x$$

(3)

$$\|A\|_2 = \max_{\substack{x \in \mathbf{R}^n \\ x \neq 0}} \frac{\|Ax\|_2}{\|x\|_2} = \sqrt{\rho(A^T A)}.$$

定理 2.4 设 $\|\cdot\|$ 是 $\mathbf{R}^{n \times n}$ 上的任意一个矩阵范数, $A \in \mathbf{R}^{n \times n}$, 则有

$$\rho(A) \leq \|A\|.$$

定理 2.5 如果 $A \in \mathbf{R}^{n \times n}$ 为对称矩阵, 则 $\rho(A) = \|A\|_2$.

定义 2.7 设 $\|\cdot\|_p$ 和 $\|\cdot\|_q$ 为 $\mathbf{R}^{n \times n}$ 上的两个范数, 如果存在正常数 c_1, c_2 , 使得对 $\forall A \in \mathbf{R}^{n \times n}$ 有

$$c_1 \|A\|_p \leq \|A\|_q \leq c_2 \|A\|_p.$$

则称 $\|\cdot\|_p$ 和 $\|\cdot\|_q$ 等价.

定理 2.6 $\mathbf{R}^{n \times n}$ 上任意两个矩阵范数都等价.

定义 2.8 设 $\|\cdot\|$ 是 $\mathbf{R}^{n \times n}$ 上的矩阵范数, $A, B \in \mathbf{R}^{n \times n}$, 称 $\|A - B\|$ 为 A 与 B 之间的距离.

定义 2.9 设 $\|\cdot\|$ 是 $\mathbf{R}^{n \times n}$ 上的矩阵范数, $A^{(0)}, A^{(1)}, \dots, A^{(k)}, \dots$ 为 $\mathbf{R}^{n \times n}$ 上的一个矩阵序列, $A \in \mathbf{R}^{n \times n}$. 如果

$$\lim_{k \rightarrow \infty} \|A^{(k)} - A\| = 0,$$

则称矩阵序列 $\{A^{(k)}\}_{k=0}^{\infty}$ 收敛于矩阵 A , 记为

$$\lim_{k \rightarrow \infty} A^{(k)} = A.$$

$$\{B^k\}_{k=0}^{\infty}$$

定理 2.7 设 $B \in \mathbb{R}^{n \times n}$, 则矩阵序列 $I, B, B^2, \dots, B^k, \dots$ 收敛于零矩阵 (即 $\lim_{k \rightarrow \infty} B^k = O$) 的充要条件是 $\rho(B) < 1$.

2.3 方程组的性态和条件数

例 2.1 考虑方程组

$$\begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

其解为 $x_1 = x_2 = 1$.

设方程组系数有小扰动, 方程组成为

$$\begin{bmatrix} 1 & -1 \\ 1 & 1.0005 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

其解为 $x_1 = x_2 = 0.99975006$.

该例子说明矩阵误差对解的影响不大.

例 2.2 考虑方程组

$$\begin{bmatrix} 10 & -10 \\ -1 & 1.001 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.001 \end{bmatrix},$$

其解为 $x_1 = x_2 = 1$.

同样, 若系数有误差, 方程组变为

$$\begin{bmatrix} 10 & -10 \\ -1 & 1.0015 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.001 \end{bmatrix},$$

其解为 $x_1 = x_2 = \frac{2}{3}$.

这个例子说明方程组的系数矩阵的误差对解的影响很大. 问题: 怎么判别?

设 A 非奇异, $b \neq 0$, 方程组 $Ax = b$ 的精确解为 x^* .

(1) 设 b 有很小的扰动 δb , 此时解 x^* 变为 $x^* + \delta x^*$, 即有

$$A(x^* + \delta x^*) = b + \delta b.$$

注意到 $Ax^* = b$, 则得

$$A\delta x^* = \delta b,$$

即

$$\delta x^* = A^{-1}\delta b.$$

两边取范数并由 矩阵范数性质 得

$$\|\delta x^*\| \leq \|A^{-1}\| \|\delta b\|.$$

另一方面, 由方程 $\underline{\|Ax^*\| = b}$ 可得

$$\|b\| \leq \|A\| \|x^*\|.$$

从而有

$$\frac{\|\delta x^*\|}{\|x^*\|} \leq \|A^{-1}\| \|A\| \frac{\|\delta b\|}{\|b\|}. \quad (2.1)$$

(2) 设 A 有微小变化 δA , 解变为 $x^* + \delta x^*$. 即

$$(A + \delta A)(x^* + \delta x^*) = b.$$

利用方程 $Ax^* = b$ 得

$$\delta A(x^* + \delta x^*) + A\delta x^* = 0, \quad \checkmark - A\delta x^*$$

即

$$\delta x^* = -A^{-1}\delta A(x^* + \delta x^*). \quad \|\delta x^*\| \leq \|A^{-1}\| \|\delta A(x^* + \delta x^*)\|$$

两边取范数得

$$\frac{\|\delta x^*\|}{\|x^* + \delta x^*\|} \leq \|A\| \|A^{-1}\| \frac{\|\delta A\|}{\|A\|}. \quad (2.2)$$

定义 2.10 设 A 为非奇异矩阵, 称 $\|A\| \|A^{-1}\|$ 为矩阵 A 的条件数, 记为

$$\text{cond}(A) = \|A\| \|A^{-1}\|. \quad \geq \|AA^{-1}\| = \|I\| = 1$$

$$\text{Cond}(A) \geq 1$$

常用的条件数

$$(1) \text{cond}(\mathbf{A})_{\infty} = \|\mathbf{A}\|_{\infty} \|\mathbf{A}^{-1}\|_{\infty}.$$

$$(2) \text{cond}(\mathbf{A})_2 = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2 = \sqrt{\frac{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}{\lambda_{\min}(\mathbf{A}^T \mathbf{A})}}.$$

当 $\mathbf{A}$ 对称正定时, $\text{cond}(\mathbf{A})_2 = \frac{\lambda_1}{\lambda_n}$

其中, $\lambda_{\max}(\mathbf{A}^T \mathbf{A})$ 和 $\lambda_{\min}(\mathbf{A}^T \mathbf{A})$ 分别为 $\mathbf{A}^T \mathbf{A}$ 的最大特征值和最小特征值, λ_1 和 λ_n 分别为 $\mathbf{A}$ 的最大特征值和最小特征值.

定义 2.11 对于方程组 $\mathbf{A}\mathbf{x} = \mathbf{b}$, 其中 $\mathbf{A}$ 非奇异. 如果 $\mathbf{A}$ 的条件数很大, 则称该方程组为病态 (坏条件) 方程组; 如果 $\mathbf{A}$ 的条件数比较小, 则称该方程组为良态 (好条件) 方程组.

可以计算例 (2.1) 中矩阵的条件数 $\text{cond}(\mathbf{A})_{\infty} = 2$, 故例 (2.1) 中的方程组是良态的. 而例 (2.2) 中矩阵的条件数 $\text{cond}(\mathbf{A})_{\infty} = 22002$, 故例 (2.1) 中的方程组是病态的.

在实际中, 由于计算 $\mathbf{A}^{-1}$ 较困难, 所以 $\text{cond}(\mathbf{A})$ 不容易计算. 但可以通过下面情形来判断病态矩阵:

(1) 用列主元 Gauss 消去法时出现绝对值很小的主元.

(2) 系数矩阵某些行 (列) 近似线性相关.

(3) 系数矩阵元素间数量级相差很大, 且没有一定规律.

对于病态方程组, 一般可以采用

(1) 双精度计算, 减少舍入误差;

(2) 对方程组进行预处理. 即选择非奇异矩阵 D, C , 将方程组 $Ax = b$ 化为等价的方程组 $DAC[C^{-1}x] = Db$, 使 DAC 的条件数比较小.

(3) 正则化方法.

2.4 方程组近似解可靠性的判别

设 $\tilde{x}$ 为方程组 $Ax = b$ 的近似解, 记 $r = b - A\tilde{x}$, 若 $r = 0$, 则 $\tilde{x}$ 为精确解. 一般 $r \neq 0$.

问题 能否根据 $\|r\|$ 的大小来判断近似解 $\tilde{x}$ 的精确程度?

定理 2.8 设 $\tilde{x}$ 是方程组 $Ax = b$ 的一个近似解, x^* 为精确解, $r = b - A\tilde{x}$. 则

$$\text{相对误差} \frac{\|x^* - \tilde{x}\|}{\|x^*\|} \leq \text{cond}(A) \frac{\|r\|}{\|b\|}$$

$\text{cond}(A)$ 小 $\rightarrow$ 良态
大 $\rightarrow$ 病态

3 线性方程组的迭代法

3.1 迭代格式的构造

设 A 非奇异, $b \neq 0$. 考虑方程组 $Ax = b$, 设其解为 x^* . 将方程组改写为等价的方程

$$x = Bx + f$$

这里 B 为 n 阶方阵, $f \in \mathbb{R}^n$. 任取一个向量 $x^{(0)} \in \mathbb{R}^n$, 产生迭代

$$x^{(k+1)} = Bx^{(k)} + f, \quad k = 0, 1, 2, \dots \quad (3.1)$$

上式产生一个向量序列 $\{x^{(k)}\}_{k=0}^{\infty}$. 若它收敛于 $\bar{x}$, 即

$$\lim_{k \rightarrow \infty} x^{(k)} = \bar{x},$$

(3.1) 两边取极限得 $\bar{x} = B\bar{x} + f$, 它等价于 $A\bar{x} = b$. 故 $\bar{x}$ 是原方程组的解, 即 $x^* = \bar{x}$.

(3.1) 称为迭代格式, B 为迭代矩阵, 称 $x^{(k)}$ 为第 k 次迭代近似解, $e^{(k)} = x^* - x^{(k)}$ 为第 k 次迭代误差. 如果迭代格式 (3.1) 对任意初始向量 $x^{(0)}$ 产生的迭代序列 $\{x^{(k)}\}_{k=0}^{\infty}$ 均收敛, 称该迭代收敛.

问题

(1) 怎样构造迭代格式? (2) 迭代何时收敛?

3.2 三个常用的迭代格式

将线性方程组 $Ax = b$ 写为分量形式

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + \cdots + a_{1n}x_n = b_1, \checkmark \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 + \cdots + a_{2n}x_n = b_2, \checkmark \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 + \cdots + a_{3n}x_n = b_3, \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + a_{n3}x_3 + \cdots + a_{nn}x_n = b_n. \end{cases}$$

假设 $a_{ii} \neq 0$ ($i = 1, 2, \dots, n$).

(1) Jacobi 迭代格式

在上述方程组中第 i 个方程求出 x_i 得

$$\begin{cases} x_1 = (b_1 - a_{12}x_2 - a_{13}x_3 - \cdots - a_{1n}x_n)/a_{11}, \checkmark \\ x_2 = (b_2 - a_{21}x_1 - a_{23}x_3 - \cdots - a_{2n}x_n)/a_{22}, \checkmark \\ x_3 = (b_3 - a_{31}x_1 - a_{32}x_2 - \cdots - a_{3n}x_n)/a_{33}, \\ \vdots \\ x_n = (b_n - a_{n1}x_1 - a_{n2}x_2 - \cdots - a_{n,n-1}x_{n-1})/a_{nn}. \end{cases}$$

$$\vec{x}^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T$$

$k+1$

k

从而产生下面的 Jacobi 迭代格式

$$\begin{cases} x_1^{(k+1)} = (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)})/a_{11}, \\ x_2^{(k+1)} = (b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)})/a_{22}, \\ x_3^{(k+1)} = (b_3 - a_{31}x_1^{(k)} - a_{32}x_2^{(k)} - \cdots - a_{3n}x_n^{(k)})/a_{33}, \\ \vdots \\ x_n^{(k+1)} = (b_n - a_{n1}x_1^{(k)} - a_{n2}x_2^{(k)} - \cdots - a_{n,n-1}x_{n-1}^{(k)})/a_{nn}, \end{cases}$$

a_{ii}^{-1}

$$\vec{x}^{k+1} = D^{-1}(\vec{b} - (L+U)\vec{x}^k) \quad k = 0, 1, \dots$$

下面将 Jacobi 迭代用矩阵和向量表示. 记

$$L = \begin{bmatrix} 0 & & & & 0 \\ a_{21} & 0 & & & \\ a_{31} & a_{32} & 0 & & \\ \vdots & \vdots & \vdots & \ddots & \\ a_{n-1,1} & a_{n-1,2} & a_{n-1,3} & \cdots & 0 \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{n,n-1} & 0 \end{bmatrix}$$

$$L+U = \begin{bmatrix} 0 & a_{12} & \cdots & a_{1n} \\ a_{21} & 0 & & a_{2n} \\ a_{31} & a_{32} & & a_{3n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & 0 \end{bmatrix}$$

$$\textcircled{D} = \begin{bmatrix} a_{11} & & & & \\ & a_{22} & & & \\ & & a_{33} & & \\ & & & \ddots & \\ & & & & a_{nn} \end{bmatrix}, \quad \textcircled{U} = \begin{bmatrix} 0 & a_{12} & a_{13} & \cdots & a_{1n} \\ & 0 & a_{23} & \cdots & a_{2n} \\ & & \ddots & \ddots & \vdots \\ & & & 0 & a_{n,n-1} \\ & & & & 0 \end{bmatrix},$$

则

$$\begin{aligned} \underline{A = L + D + U} &\implies \\ Ax = b &\iff (L + D + U)x = b \\ \implies Dx &= -(L + U)x + b \\ \implies x &= -\underline{D^{-1}(L + U)}x + D^{-1}b. \end{aligned}$$

Jacobi 迭代格式:

$$\underline{x^{(k+1)} = Jx^{(k)} + f_J}, \quad k = 0, 1, \dots,$$

其中

$$\underline{J = -D^{-1}(L + U), \quad f_J = D^{-1}b.}$$

(2) Gauss-Seidel 迭代格式

在 Jacobi 迭代中将已经求出的分量直接参加下一个分量的计算, 得到下面的 Gauss-Seidel 迭代格式:

$$\begin{cases} x_1^{(k+1)} = (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)})/a_{11}, \\ x_2^{(k+1)} = (b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)})/a_{22}, \\ x_3^{(k+1)} = (b_3 - a_{31}x_1^{(k+1)} - a_{32}x_2^{(k+1)} - a_{34}x_4^{(k)} - \cdots - a_{3n}x_n^{(k)})/a_{33}, \\ \vdots \\ x_n^{(k+1)} = (b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \cdots - a_{n,n-1}x_{n-1}^{(k+1)})/a_{nn}, \end{cases} \quad k = 0, 1, \dots$$

用矩阵表示为:

$$\begin{aligned} \mathbf{x}^{(k+1)} &= \mathbf{D}^{-1}(\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1)} - \mathbf{U}\mathbf{x}^{(k)}), \\ \Rightarrow (\mathbf{D} + \mathbf{L})\mathbf{x}^{(k+1)} &= \mathbf{b} - \mathbf{U}\mathbf{x}^{(k)}. \end{aligned}$$

Gauss-Seidel 迭代格式:

$$\mathbf{x}^{(k+1)} = \mathbf{G}\mathbf{x}^{(k)} + \mathbf{f}_G, \quad k = 0, 1, \dots,$$

其中

$$\mathbf{G} = -(\mathbf{D} + \mathbf{L})^{-1}\mathbf{U}, \quad \mathbf{f}_G = (\mathbf{D} + \mathbf{L})^{-1}\mathbf{b}.$$

(3) SOR(逐次超松弛) 迭代格式

已知 $\mathbf{x}^{(k)} = (x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)})^T$, 将 Gauss-Seidel 迭代中的 $\mathbf{x}^{(k+1)}$ 与 $\mathbf{x}^{(k)}$ 加权平均, 得到 SOR 迭代:

$$\begin{cases} x_1^{(k+1)} = (1 - \omega)x_1^{(k)} + \omega(b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)})/a_{11}, \\ x_2^{(k+1)} = (1 - \omega)x_2^{(k)} + \omega(b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)})/a_{22}, \\ \vdots \\ x_n^{(k+1)} = (1 - \omega)x_n^{(k)} + \omega(b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \dots - a_{nn-1}x_{n-1}^{(k+1)})/a_{nn}, \end{cases}$$

$$\mathbf{x}^{(k+1)} = (1 - \omega)\mathbf{x}^{(k)} + \omega \left(\mathbf{D}^{-1}(\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1)} - \mathbf{U}\mathbf{x}^{(k)}) \right), \quad k = 0, 1, \dots,$$

其中 ω 称为松弛因子. 当 $\omega = 1$, 上式成为 Gauss-Seidel 迭代.

将 SOR 迭代用矩阵表示:

$$\mathbf{x}^{(k+1)} = (1 - \omega)\mathbf{x}^{(k)} + \omega\mathbf{D}^{-1}(\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1)} - \mathbf{U}\mathbf{x}^{(k)}), \Rightarrow$$

$$\mathbf{D}\mathbf{x}^{(k+1)} = (1 - \omega)\mathbf{D}\mathbf{x}^{(k)} + \omega(\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1)} - \mathbf{U}\mathbf{x}^{(k)}), \Rightarrow$$

$$(\mathbf{D} + \omega\mathbf{L})\mathbf{x}^{(k+1)} = [(1 - \omega)\mathbf{D} - \omega\mathbf{U}]\mathbf{x}^{(k)} + \omega\mathbf{b}, \Rightarrow$$

$$\mathbf{x}^{(k+1)} = \mathbf{S}_\omega \mathbf{x}^{(k)} + \mathbf{f}_\omega,$$

$$(\mathbf{D} + \omega\mathbf{L})^{-1}$$

其中

$$\mathbf{S}_\omega = (\mathbf{D} + \omega\mathbf{L})^{-1}[(1 - \omega)\mathbf{D} - \omega\mathbf{U}], \quad \mathbf{f}_\omega = \omega(\mathbf{D} + \omega\mathbf{L})^{-1}\mathbf{b}.$$

3.3 迭代格式的收敛性

(1) 迭代法基本定理

定理 3.1 迭代格式 $\underline{x^{(k+1)} = Bx^{(k)} + f}$ ($k = 0, 1, 2, \dots$) 收敛 $\iff \rho(B) < 1$.

定理 3.2 若迭代矩阵 $\|B\| < 1$, 则迭代 $x^{(k+1)} = Bx^{(k)} + f$ 收敛.

我们还可以证明: 若 $\|B\| < 1$, 则对 $k = 1, 2, 3, \dots$ 有

$$\|x^* - x^{(k)}\| \leq \frac{\|B\|}{1 - \|B\|} \|x^{(k)} - x^{(k-1)}\|,$$
$$\|x^* - x^{(k)}\| \leq \frac{\|B\|^k}{1 - \|B\|} \|x^{(1)} - x^{(0)}\|.$$

(2) Jacobi 迭代和 Gauss-Seidel 迭代的收敛性

由定理 3.1, Jacobi 迭代收敛 $\iff \rho(J) < 1$. J 的特征方程为

$$|\lambda I - J| = |\lambda I + D^{-1}(\tilde{L} + U)| = |D^{-1}(\lambda D + L + U)| = 0.$$
$$\iff |\lambda D + L + U| = 0.$$

例 3.1 给定线性方程组

$$\begin{bmatrix} 8 & -1 & 1 \\ 2 & 10 & -1 \\ 1 & 1 & -5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \\ 3 \end{bmatrix}.$$

$$\tilde{A} = L + \lambda D + U$$

$$\begin{pmatrix} a_{11} & a_{12} & a_{1n} \\ a_{21} & \lambda a_{22} & a_{2n} \\ a_{n1} & a_{nm} & \lambda a_{nn} \end{pmatrix}$$

- (1) 写出 Jacobi 迭代格式.
- (2) 分析 Jacobi 迭代格式的收敛性.

解 (1) Jacobi 迭代格式为

$$\begin{cases} x_1^{(k+1)} = (1 + x_2^{(k)} - x_3^{(k)})/8, \\ x_2^{(k+1)} = (4 - 2x_1^{(k)} + x_3^{(k)})/10, \\ x_3^{(k+1)} = (3 - x_1^{(k)} - x_2^{(k)})/(-5). \end{cases}$$

(2) Jacobi 迭代矩阵 J 的特征方程为

$$\begin{vmatrix} 8\lambda & -1 & 1 \\ 2 & 10\lambda & -1 \\ 1 & 1 & -5\lambda \end{vmatrix} = 0,$$

展开得

$$400\lambda^3 + 12\lambda - 3 = 0,$$

用 Newton 迭代法求得一个实根为 $\lambda_1 = 0.146084$. 记另两根为 λ_2, λ_3 , 通过待定系数可得

$$(\lambda - \lambda_1)(400\lambda^2 + b\lambda + c) = 0,$$

其中

$$b = \frac{1}{400\lambda_1}, \quad c = \frac{3}{\lambda_1}.$$

易知 λ_1, λ_2 为共轭复根, 且有

$$|\lambda_2\lambda_3| = \frac{3}{400\lambda_1},$$

$$|\lambda_1| = |\lambda_2| = \sqrt{\frac{3}{400\lambda_1}} = 0.226584,$$

所以

$$\rho(\mathbf{J}) = \max_{i=1,2,3} \{|\lambda_i|\} = 0.226584 < 1,$$

Jacobi 迭代收敛.

同样由定理 3.1, Gauss-Seidel 迭代收敛 $\iff \rho(\mathbf{G}) < 1$. $\mathbf{G}$ 的特征方程为

$$\begin{aligned} |\lambda \mathbf{I} - \mathbf{G}| &= |\lambda \mathbf{I} + (\mathbf{D} + \mathbf{L})^{-1} \mathbf{U}| \\ &= |(\mathbf{D} + \mathbf{L})^{-1} (\lambda(\mathbf{D} + \mathbf{L}) + \mathbf{U})| = 0. \\ &\iff |(\lambda(\mathbf{D} + \mathbf{L}) + \mathbf{U})| = 0. \end{aligned}$$

$$\mathbf{G} = -(\mathbf{D} + \mathbf{L})^{-1} \mathbf{U}$$

$$\mathbf{G} \vec{x} = \lambda \vec{x} \quad (\lambda \mathbf{I} - \mathbf{G}) \vec{x} = 0$$

$\mathbf{U} \rightarrow$ 不变.

$$\begin{pmatrix} \lambda \mathbf{D} \\ \lambda \mathbf{L} \end{pmatrix}$$

例 3.2 给定线性方程组

$$\begin{bmatrix} 8 & -1 & 1 \\ 2 & 10 & -1 \\ 1 & 1 & -5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \\ 3 \end{bmatrix}.$$

- (1) 写出 Gauss-Seidel 迭代格式.
- (2) 分析 Gauss-Seidel 迭代格式的收敛性.

解 (1) Gauss-Seidel 迭代格式为

$$\begin{cases} x_1^{(k+1)} = (1 + x_2^{(k)} - x_3^{(k)})/8, \\ x_2^{(k+1)} = (4 - 2x_1^{(k+1)} + x_3^{(k)})/10, \\ x_3^{(k+1)} = (3 - x_1^{(k+1)} - x_2^{(k+1)})/(-5). \end{cases}$$

(2) Gauss-Seidel 迭代矩阵 G 的特征方程为

$$\begin{vmatrix} 8\lambda & -1 & 1 \\ 2\lambda & 10\lambda & -1 \\ \lambda & \lambda & -5\lambda \end{vmatrix} = 0,$$

展开得

$$\lambda(400\lambda^2 + 10\lambda - 1),$$

求得

$$\lambda_1 = 0, \quad \lambda_2 = \frac{-1 + \sqrt{17}}{80}, \quad \lambda_3 = \frac{-1 - \sqrt{17}}{80},$$

$$\rho(\mathbf{G}) = \max_{i=1,2,3} \{|\lambda_i|\} = 0.0640388 < 1,$$

Gauss-Seidel 迭代收敛.

定义 3.1 设

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

如果

$$|a_{ii}| > \sum_{\substack{j=1 \\ i \neq j}}^n |a_{ij}|, \quad i = 1, 2, \dots, n$$

则称 A 按行严格对角占优；如果

$$|a_{jj}| > \sum_{\substack{i=1 \\ j \neq i}}^n |a_{ij}|, \quad j = 1, 2, \dots, n$$

则称 A 按列严格对角占优。按行严格对角占优或按列严格对角占优统称为严格对角占优。

引理 3.1 设 A 是严格对角占优矩阵, 则 $|A| \neq 0$.

A 可逆, $\exists A^{-1}$

A^{-1}

$$A\vec{x}^* = \vec{0}$$

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1k} & \cdots & a_{1n} \\ & & & & & \\ a_{k1} & a_{k2} & \cdots & a_{kk} & \cdots & a_{kn} \\ & & & & & \\ a_{n1} & a_{n2} & \cdots & a_{nk} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} x_1^* \\ x_2^* \\ \vdots \\ x_k^* \\ \vdots \\ x_n^* \end{pmatrix} = \vec{0}$$

$$a_{k1}x_1^* + a_{k2}x_2^* + \cdots +$$

$$a_{kk}x_k^* + \cdots + a_{kn}x_n^* = 0$$

证 这里仅证 A 是按行严格对角占优的情况. 用反证法.

设 $|A| \neq 0$, 则齐次方程组 $Ax = 0$ 有非零解 $x^* = (x_1^*, x_2^*, \dots, x_n^*)^T$.

设 $\|x^*\|_\infty = |x_k^*| \neq 0$. 由第 k 个方程

$$|A| = 0$$

$$a_{kk}x_k^* + \sum_{j=1, j \neq k}^n a_{kj}x_j^* = 0$$

$$\|x^*\|_\infty = |x_k^*|$$

$$|x_j^*| \leq |x_k^*|$$

可得

$$|a_{kk}| \cdot |x_k^*| = \left| \sum_{j=1, j \neq k}^n a_{kj}x_j^* \right| \leq \sum_{j=1, j \neq k}^n |a_{kj}| \cdot |x_j^*|$$

$$\leq \sum_{j=1, j \neq k}^n |a_{kj}| \cdot |x_k^*| = |x_k^*| \sum_{j=1, j \neq k}^n |a_{kj}|$$

两边约去 $|x_k^*|$, 得

$$|a_{kk}| \leq \sum_{j=1, j \neq k}^n |a_{kj}|$$

与按行严格对角占优矛盾. 因而 $|A| \neq 0$.

$$|a_{kk}| > \sum_{j=1, j \neq k}^n |a_{kj}|$$

定理 3.3 给定线性方程组 $Ax = b$, 如果 A 是严格对角占优矩阵, 则 Jacobi 迭代格式收敛.

证明 记

$$\mathbf{B}(\lambda) = \begin{pmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & \lambda a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & \lambda a_{nn} \end{pmatrix}$$

则 Jacobi 迭代矩阵 $\mathbf{J}$ 的特征方程为 $|\mathbf{B}(\lambda)| = 0$ 。设 $\mathbf{A}$ 是按行严格对角占优的, 则当 $|\lambda| \geq 1$ 时, 有

$$|\lambda| |a_{ii}| = |\lambda a_{ii}| \geq |a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}| \quad (i = 1, 2, \dots, n)$$

$|\lambda| \geq 1$
等号不成立
无根

即 $\mathbf{B}(\lambda)$ 是严格按行对角占优的。由上面的一个引理可知, 当 $|\lambda| \geq 1$ 时, $|\mathbf{B}(\lambda)| \neq 0$ 。换句话说, 方程 $|\mathbf{B}(\lambda)| = 0$ 的 n 个根 $\lambda_1, \lambda_2, \dots, \lambda_n$ 都应满足 $|\lambda_i| < 1, i = 1, 2, \dots, n$ 。于是 $\rho(\mathbf{J}) < 1$ 。同样可证当 $\mathbf{A}$ 按列严格对角占优的情况。因而 Jacobi 迭代格式收敛。

定理 3.4 给定线性方程组 $Ax = b$, 如果 A 是严格对角占优矩阵, 则 Gauss-Seidel 迭代格式收敛.

充分条件

严格对角占优 $\Rightarrow$ 收敛

~~充分条件~~

142 x

证 记

$$C(\lambda) = \begin{pmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n} \\ \lambda a_{21} & \lambda a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ \lambda a_{n1} & \lambda a_{n2} & \cdots & \lambda a_{nn} \end{pmatrix}$$

则 Gauss-Seidel 迭代矩阵 G 的特征方程为 $|C(\lambda)| = 0$. 设 A 是按行严格对角占优的, 则当 $|\lambda| \geq 1$ 时, 有

$$\begin{aligned} |\lambda a_{ii}| &= |\lambda| |a_{ii}| > |\lambda| \sum_{j=1, j \neq i}^n |a_{ij}| \\ &\geq |\lambda| \sum_{j=1}^{i-1} |a_{ij}| + \sum_{j=i+1}^n |a_{ij}|, i = 1, 2, \dots, n \end{aligned}$$

即 $C(\lambda)$ 是严格按行对角占优的。由上面的一个引理可知, 当 $|\lambda| \geq 1$ 时, $|C(\lambda)| \neq 0$. 换句话说, 方程 $|C(\lambda)| = 0$ 的 n 个根 $\lambda_1, \lambda_2, \dots, \lambda_n$ 都应满足 $|\lambda_i| < 1, i = 1, 2, \dots, n$. 于是 $\rho(G) < 1$. 同样可证当 A 按列严格对角占优的情况。因而 Gauss-Seidel 迭代格式收敛。

注 3.1 由定理3.3 和定理3.4 知, 例3.1 和例3.2 中的系数矩阵严格对角占优, 故 Jacobi 迭代和 Gauss-Seidel 迭代均收敛.

SOR 迭代的迭代矩阵为

由定理 3.1, SOR 迭代收敛 $\iff \rho(S_\omega) < 1$.

5/24

⏮ ⏪ ⏩ ⏭ 🔍 ✕

证 设 S_ω 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 则由线性代数知

$$|\det(S_\omega)| = |\lambda_1 \lambda_2 \cdots \lambda_n| \leq \rho(S_\omega)^n.$$

另一方面, 由定理 3.1, 若 SOR 收敛, 则 $\rho(S_\omega) < 1$, 从而有 $|\det(S_\omega)| < 1$. 而行列式

$$\begin{aligned} \det(S_\omega) &= \det[(\mathbf{D} + \omega \mathbf{L})^{-1}] \det[(1 - \omega) \mathbf{D} - \omega \mathbf{U}] \\ &= \left(\prod_{i=1}^n a_{ii} \right)^{-1} \prod_{i=1}^n [(1 - \omega) a_{ii}] \\ &= (1 - \omega)^n. \end{aligned}$$

从而有

$$|(1 - \omega)^n| < 1, \quad \Rightarrow 0 < \omega < 2.$$

$$|1 - \omega| < 1$$

$$\begin{pmatrix} (1-\omega)a_{11} & & & \\ & (1-\omega)a_{22} & & \\ & & \ddots & \\ & & & (1-\omega)a_{nn} \end{pmatrix} \quad \omega \mathbf{U}$$

$$\begin{pmatrix} a_{11}^{-1} & & & \\ \omega a_{12} & a_{22}^{-1} & & \\ & & \ddots & \\ \omega a_{1n} & & & a_{nn}^{-1} \end{pmatrix}$$

定理 3.6 给定线性方程组 $Ax = b$. 如果 A 对称正定, 且 $0 < \omega < 2$, 则 SOR 迭代收敛.

注 3.2 如果 A 对称正定, 则 Gauss-Seidel 迭代收敛.

$$\omega = 1$$

$$A^T = A$$
$$\vec{x}^T A \vec{x} > 0$$

例 3.3 给定线性方程组

$$\begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

(a) 分别写出解该方程组的 Jacobi 迭代 和 Gauss-Seidel 迭代格式.

(b) 分析这两种迭代格式的收敛性.

解

(a) Jacobi 迭代格式为

$$\begin{cases} x_1^{(k+1)} = (-x_2^{(k)} - x_3^{(k)} + 1)/2, \\ x_2^{(k+1)} = (-x_1^{(k)} - x_3^{(k)} + 2)/2, \\ x_3^{(k+1)} = (-x_1^{(k)} - x_2^{(k)} + 3)/2. \end{cases} \quad k = 0, 1, \dots$$

Gauss-Seidel 迭代格式为

$$\begin{cases} x_1^{(k+1)} = (-x_2^{(k)} - x_3^{(k)} + 1)/2, \\ x_2^{(k+1)} = (-x_1^{(k+1)} - x_3^{(k)} + 2)/2, \quad k = 0, 1, \dots \\ x_3^{(k+1)} = (-x_1^{(k+1)} - x_2^{(k+1)} + 3)/2. \end{cases}$$

(b) Jacobi 迭代矩阵 $\mathbf{J}$ 的特征方程为

$$\begin{vmatrix} 2\lambda & 1 & 1 \\ 1 & 2\lambda & 1 \\ 1 & 1 & 2\lambda \end{vmatrix} = 0,$$

展开得

$$4\lambda^3 - 3\lambda + 1 = 0,$$

即有

$$(2\lambda - 1)^2(\lambda + 1) = 0,$$

求得

$$\lambda_{1,2} = \frac{1}{2}, \quad \lambda_3 = -1,$$

所以 $\rho(\mathbf{J}) = 1$, 故 Jacobi 迭代发散.

$$\rho(\mathbf{J}) < 1$$

Gauss-Seidel 迭代矩阵 $\mathbf{G}$ 的特征方程是

$$\begin{vmatrix} 2\lambda & 1 & 1 \\ \lambda & 2\lambda & 1 \\ \lambda & \lambda & 2\lambda \end{vmatrix} = 0,$$

展开得

$$\lambda(8\lambda^2 - 2\lambda + 1) = 0,$$

求得

$$\lambda_1 = 0, \quad \lambda_{2,3} = \frac{1 \pm \sqrt{7}i}{8},$$

所以 $\rho(\mathbf{G}) = \frac{\sqrt{2}}{4} < 1$, 故 Gauss-Seidel 迭代收敛.

$$\underline{x^{(k+1)}} = \bigcirc x^{(k)} + \dots$$

例 3.4 给定线性方程组 $Ax = b$, A 为 n 阶非奇异矩阵. 构造迭代

$$x^{(k+1)} = x^{(k)} + \omega(b - Ax^{(k)}), \quad (k = 0, 1, 2, \dots)$$

其中 $\omega \neq 0$ 为常数. $= (I - \omega A)x^{(k)} + \omega b$

(a) 证明: 如果迭代收敛, 则迭代序列 $\{x^{(k)}\}_{k=0}^{\infty}$ 收敛于方程 $Ax = b$ 的解.

(b) 设 $A = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix}$, 则 ω 取何值时迭代收敛?

解

(a) 证 设 $\lim_{k \rightarrow \infty} x^{(k)} = x^*$, 在迭代格式两边取极限

$$\lim_{k \rightarrow \infty} x^{(k+1)} = \lim_{k \rightarrow \infty} [x^{(k)} + \omega(b - Ax^{(k)})].$$

得 $x^* = x^* + \omega(b - Ax^*)$. 因为 $\omega \neq 0$, 所以 $Ax^* = b$, 即 x^* 是方程 $Ax = b$ 的解.

(b) 迭代格式的迭代矩阵为 $I - \omega A$, 迭代收敛 $\iff \rho(I -$

$\omega \mathbf{A}) < 1$. 矩阵 $\mathbf{I} - \omega \mathbf{A}$ 的特征方程为

$$|\lambda \mathbf{I} - (\mathbf{I} - \omega \mathbf{A})| = \begin{vmatrix} (\lambda - 1 + 2\omega) & \omega & \omega \\ \omega & (\lambda - 1 + 2\omega) & \omega \\ \omega & \omega & (\lambda - 1 + 2\omega) \end{vmatrix} = 0,$$

$$\text{记 } \mu = (\lambda - 1 + 2\omega), \implies \mu^3 - 3\omega^2\mu + 2\omega^3 = 0,$$

$$\implies (\mu - \omega)^2(\mu + 2\omega) = 0.$$

$$\implies \mu = \omega \text{ 或 } \mu = -2\omega, \implies \lambda = 1 - \omega \text{ 或 } \lambda = 1 - 4\omega.$$

$$\begin{cases} |1 - \omega| < 1 \\ |1 - 4\omega| < 1 \end{cases} \implies 0 < \omega < \frac{1}{2}.$$

4 幂法与反幂法

幂法和反幂法是迭代法. 幂法用于求矩阵按模最大的特征值和对应的特征向量. 当特征值非零时, 反幂法用于求按模最小的特征值和对应的特征向量.

$$|A| \neq 0$$

4.1 求主特征值的幂法

设 $A = (a_{ij})_{n \times n}$ 是 n 阶方阵, 它有 n 个线性无关的特征向量 $x_1, x_2, \dots, x_n$, 对应的特征值为 $\lambda_j (j = 1, 2, \dots, n)$, 按模的大小排列

$$|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|,$$

其中 λ_1 是主特征值. 给定初值非零向量 v_0 , 构造迭代

$$v_k = Av_{k-1}, \quad k = 1, 2, \dots$$

v_0 可由 $x_1, x_2, \dots, x_n$ 线性表示, 设表示为

$$v_0 = \sum_{i=1}^n a_i x_i,$$

$$A^2 x_i = A(Ax_i)$$

$$= A\lambda_i x_i$$

$$= \lambda_i A x_i = \lambda_i^2 x_i$$

且 $a_1 \neq 0$. 因此有

$$\underline{\mathbf{v}_k = \mathbf{A}\mathbf{v}_{k-1} = \mathbf{A}^k \mathbf{v}_0 = \mathbf{A}^k \sum_{i=1}^n a_i \mathbf{x}_i = \sum_{i=1}^n a_i \lambda_i^k \mathbf{x}_i, \quad k = 1, 2, \dots}$$

$= \sum_{i=1}^n a_i \lambda_i^k \mathbf{x}_i$

(1) 特征值满足 $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$. 则

$$\mathbf{v}_k = \lambda_1^k \left[a_1 \mathbf{x}_1 + a_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}_2 + \dots + a_n \left(\frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}_n \right]$$
$$\mathbf{v}_{k+1} = \lambda_1^{k+1} \left[a_1 \mathbf{x}_1 + a_2 \left(\frac{\lambda_2}{\lambda_1} \right)^{k+1} \mathbf{x}_2 + \dots + a_n \left(\frac{\lambda_n}{\lambda_1} \right)^{k+1} \mathbf{x}_n \right]$$

因为

$$|\lambda_1| > |\lambda_i| \quad i = 2, 3, \dots, n,$$

故

$$\lim_{k \rightarrow \infty} \left(\frac{\lambda_i}{\lambda_1} \right)^k = 0, \quad i = 2, 3, \dots, n.$$

从而当 k 充分大, 有

$$\underline{\mathbf{v}_k \approx a_1 \lambda_1^k \mathbf{x}_1}, \quad \underline{\mathbf{v}_{k+1} \approx a_1 \lambda_1^{k+1} \mathbf{x}_1 \approx \lambda_1 \mathbf{v}_k}. \quad (4.1)$$

由上式知 $\mathbf{v}_{k+1} = \mathbf{A}\mathbf{v}_k \approx \lambda_1 \mathbf{v}_k$. 该式说明 $\mathbf{v}_k$ 是 λ_1 对应的近似特征向量, $\mathbf{v}_k$ 和 $\mathbf{v}_{k+1}$ 近似线性相关. 所以

$$\lambda_1 = \lim_{k \rightarrow \infty} \frac{(\mathbf{v}_{k+1})_i}{(\mathbf{v}_k)_i},$$

其中 $(\mathbf{v}_k)_i$ 表示 $\mathbf{v}_k$ 的第 i 个分量. 实际计算时, 为了避免 $\mathbf{v}_k$ 的分量产生溢出, 可以采用“归一化”, 具体将算法改为:

$$\begin{cases} \mathbf{u}_0 = \mathbf{v}_0, \\ \mathbf{v}_k = \mathbf{A}\mathbf{u}_{k-1}, \\ m_k = \max(\mathbf{v}_k), \\ \mathbf{u}_k = \mathbf{v}_k / m_k, \end{cases} \quad k = 1, 2, \dots, \quad (4.2)$$

其中 $m_k = \max(\mathbf{v}_k)$ 表示 $\mathbf{v}_k$ 中 (首次出现的) 绝对值最大的分量.

定理 4.1 设 $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$, 则由算法 (4.2) 产生的序列 $\{u_k\}$ 和 $\{m_k\}$ 均收敛, 且

4/25/2020

$$\lim_{k \rightarrow \infty} u_k = \frac{x_1}{\max(x_1)}, \quad \lim_{k \rightarrow \infty} m_k = \lambda_1.$$

证

$$\mathbf{u}_k = \frac{1}{m_k} \mathbf{v}_k = \frac{1}{m_k} \mathbf{A} \mathbf{u}_{k-1}, \quad k = 1, 2, \dots,$$

利用上式递推得

$$\begin{aligned} \mathbf{u}_k &= \frac{1}{m_k} \mathbf{A} \left(\frac{1}{m_{k-1}} \mathbf{A} \mathbf{u}_{k-2} \right) \\ &= \frac{1}{m_k m_{k-1}} \mathbf{A}^2 \mathbf{u}_{k-2} \\ &= \dots \\ &= \frac{1}{m_k m_{k-1} \cdots m_1} \mathbf{A}^k \mathbf{u}_0. \end{aligned}$$

由 $\mathbf{u}_k$ 的归一化, $m_k m_{k-1} \cdots m_1 = \frac{\max(\mathbf{A}^k \mathbf{u}_0)}{\max(\mathbf{u}_k)} = \max(\mathbf{A}^k \mathbf{u}_0),$

$$\mathbf{u}_k = \frac{\mathbf{A}^k \mathbf{u}_0}{\max(\mathbf{A}^k \mathbf{u}_0)}$$

$$\begin{aligned}
&= \frac{\lambda_1^k \left(a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}{\max \left(\lambda_1^k \left(a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right) \right)} \\
&= \frac{a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i}{\max \left(a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}.
\end{aligned}$$

从而

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{\mathbf{x}_1}{\max(\mathbf{x}_1)}.$$

同样

$$\mathbf{v}_k = \mathbf{A} \mathbf{u}_{k-1} = \frac{\mathbf{A}^k \mathbf{u}_0}{\max(\mathbf{A}^{k-1} \mathbf{u}_0)}$$

$$= \frac{\lambda_1 \max \left(a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}{\max \left(a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left(\frac{\lambda_i}{\lambda_1} \right)^{k-1} \mathbf{x}_i \right)}.$$

因此

$$\lim_{k \rightarrow \infty} \max(\mathbf{v}_k) = \lambda_1.$$

从以上分析知幂法的收敛速度与 $\left| \frac{\lambda_2}{\lambda_1} \right|$ 有关, 称比值 $\left| \frac{\lambda_2}{\lambda_1} \right|$ 为幂法的收敛速率.

例 4.1 用幂法计算矩阵

$$\mathbf{A} = \begin{bmatrix} 2 & 3 & 2 \\ 10 & 3 & 4 \\ 3 & 6 & 1 \end{bmatrix}$$

的主特征值及对应的特征向量.

解 取 $\mathbf{u}_0 = (0, 0, 1)^T$, 由 (4.2) 构造迭代

$$\mathbf{u}_0 = \mathbf{v}_0,$$

$$\mathbf{v}_k = \mathbf{A}\mathbf{u}_{k-1},$$

$$m_k = \max(\mathbf{v}_k),$$

$$\mathbf{u}_k = \mathbf{v}_k/m_k, \quad k = 1, 2, \dots$$

计算结果见表6.1.

表 6.1 幂法求主特征值

k	$\mathbf{u}_k^T$	m_k
0	(0, 0, 1)	1
1	(0.5, 1.0, 0.25)	4
2	(0.5, 1.0, 0.8611)	9
3	(0.5, 1.0, 0.7306)	11.4400
4	(0.5, 1.0, 0.7535)	10.9224
5	(0.5, 1.0, 0.7493)	11.0140
6	(0.5, 1.0, 0.7501)	10.9927
7	(0.5, 1.0, 0.7500)	11.0004
8	(0.5, 1.0, 0.7500)	11.0000

(2) 当 $|\lambda_1| = |\lambda_2|$, 且 $|\lambda_2| > |\lambda_3|$ 时.

(a) $\lambda_1 = \lambda_2$.

$$\begin{aligned}\mathbf{u}_k &= \frac{\mathbf{A}^k \mathbf{u}_0}{\max(\mathbf{A}^k \mathbf{u}_0)} \\ &= \frac{a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1}\right)^k \mathbf{x}_i}{\max\left(a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1}\right)^k \mathbf{x}_i\right)}\end{aligned}$$

因此

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2}{\max(a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2)}.$$

$$\lim_{k \rightarrow \infty} m_k = \lim_{k \rightarrow \infty} \max(\mathbf{v}_k) = \lambda_1.$$

(b) $\lambda_1 = -\lambda_2$

(c) $\lambda_1 = \bar{\lambda}_2$

4.2 反幂法

当 A 非奇异时, A 的特征值非零. A^{-1} 的按模最大特征值就是 A 的按模最小的特征值. 因此用幂法可以求 A^{-1} 的按模最大的特征值即 A 的按模最小的特征值, 这就是反幂法. 算法如下:

$$\begin{cases} \mathbf{u}_0 = \mathbf{v}_0 \\ \mathbf{A}\mathbf{v}_k = \mathbf{u}_{k-1} \\ m_k = \max(\mathbf{v}_k) \\ \mathbf{u}_k = \mathbf{v}_k / m_k \end{cases} \quad k = 1, 2, \dots$$

易知

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{\mathbf{x}_n}{\max(\mathbf{x}_n)}, \quad \lim_{k \rightarrow \infty} m_k = \frac{1}{\lambda_n}$$

$$A \tilde{\mathbf{x}}_i = \lambda_i \tilde{\mathbf{x}}_i, \quad \tilde{\mathbf{x}}_i = \lambda_i A^{-1} \tilde{\mathbf{x}}_i$$

$$A^{-1} \tilde{\mathbf{x}}_i = \frac{1}{\lambda_i} \tilde{\mathbf{x}}_i$$

$$A^{-1}$$

$$\left| \frac{1}{\lambda_i} \right|$$

解

$$\begin{array}{c}
 \begin{array}{c} A \quad b \\
 \left[\begin{array}{ccc|c}
 3 & 1 & -1 & 4 \\
 4 & 0 & 4 & 8 \\
 12 & -3 & 3 & 9
 \end{array} \right] \xrightarrow{r_1 \leftrightarrow r_3} \left[\begin{array}{ccc|c}
 12 & -3 & 3 & 9 \\
 4 & 0 & 4 & 8 \\
 3 & 1 & -1 & 4
 \end{array} \right] \xrightarrow{\begin{array}{l} -\frac{1}{3}r_1 + r_2 \\ -\frac{1}{4}r_1 + r_3 \end{array}} \\
 \left[\begin{array}{ccc|c}
 12 & -3 & 3 & 9 \\
 0 & 1 & 3 & 5 \\
 0 & 7 & 7 & 7 \\
 0 & 4 & -4 & 4
 \end{array} \right] \xrightarrow{r_2 \leftrightarrow r_3} \left[\begin{array}{ccc|c}
 12 & -3 & 3 & 9 \\
 0 & 7 & 7 & 7 \\
 0 & 4 & -4 & 4
 \end{array} \right] \xrightarrow{-\frac{4}{7}r_2 + r_3} \\
 \left[\begin{array}{ccc|c}
 12 & -3 & 3 & 9 \\
 0 & 7 & 7 & 7 \\
 0 & 0 & 4 & 4
 \end{array} \right]
 \end{array}
 \end{array}$$

回代得 $x_1 = 1, \quad x_2 = 2, \quad x_3 = 1.$

$$\begin{pmatrix} -12 & -3 & 3 \\ 7/4 & -7/4 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 9 \\ 7 \\ 4 \end{pmatrix}$$

最大值 $\max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq 0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}$ 能否取到? 由定理 2.1 知, 对 $\forall \mathbf{x} \in \mathbf{R}^n$, $\|\mathbf{Ax}\|$ 在 $\mathbf{R}^n$ 上连续. 记

$$\mathbf{S} = \{\mathbf{y} | \mathbf{y} \in \mathbf{R}^n, \|\mathbf{y}\| = 1\},$$

$\mathbf{S}$ 是有界闭集. $\|\mathbf{Ax}\|$ 在 $\mathbf{S}$ 上能取到最大值, 设最大值为 M . 即存在 $\mathbf{y}_0 \in \mathbf{S}$ 使得

$$\max_{\mathbf{y} \in \mathbf{S}} \|\mathbf{Ay}\| = \|\mathbf{Ay}_0\| = M.$$

故对 $\forall \mathbf{x} \in \mathbf{R}^n, \mathbf{x} \neq 0$, 有 $\frac{\mathbf{x}}{\|\mathbf{x}\|} \in \mathbf{S}$, 令 $\mathbf{y} = \frac{\mathbf{x}}{\|\mathbf{x}\|}$, 有

$$\max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq 0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} = \max_{\mathbf{y} \in \mathbf{S}} \|\mathbf{Ay}\| = M.$$

5 习题

习题 3 p.120

1, 5(2), 9, 17, 19, 20, 23, 25, 27, 28, 30, 32(1)(2), 34, 39(上机题)

40, 41